

UNIVERSIDAD
NACIONAL
DE COLOMBIA

**Anotación funcional de microdominios en proteínas
secretadas por la microbiota asociada a
Caenorhabditis elegans mediante integración de
información de secuencia, estructura y aprendizaje
automático**

Daniela Ardila Parrado

Universidad Nacional de Colombia
Facultad de ciencias, Departamento de biología
Bogotá, Colombia, 2025

**Anotación funcional de microdominios en
proteínas secretadas por la microbiota asociada
a *Caenorhabditis elegans* mediante integración
de información de secuencia, estructura y
aprendizaje automático**

Daniela Ardila Parrado

Tesis o trabajo de investigación presentada(o) como requisito parcial para optar al
título de:

Profesional en Biología

Director (a):

Maryam Chaib De Mares

Doctora en Biología

Profesora Asociada – Departamento de Biología

Universidad Nacional de Colombia

Línea de Investigación:

Biología Molecular y Bioinformática

Grupo de Investigación:

BMTE - Biología molecular, teórica y evolutiva

Universidad Nacional de Colombia

Facultad de Ciencias

Departamento de Biología

Bogotá, Colombia

2025

Resumen

La microbiota animal secreta proteínas que actúan como señales o efectores y modulan procesos del hospedero como la inmunidad, el desarrollo y la longevidad. Sin embargo, la anotación funcional de estas proteínas sigue siendo deficiente porque los métodos basados en homología detectan con poca sensibilidad microdominios y motivos cortos. Para solucionar esta carencia, se seleccionó un conjunto representativo de 22 proteínas secretadas bacterianas con evidencia experimental. A través de un flujo de trabajo integrativo, se detectaron microdominios adicionales con herramientas como InterProScan y ScanProsite, con una generación de modelos estructurales con AlphaFold2. Además, se recuperaron los términos Gene Ontology (GO) para cada proteína, evaluando con esto el enriquecimiento funcional, por medio de pruebas hipergeométricas y de Fisher, y generando una visualización de las diferencias funcionales. El análisis reveló que las proteínas cortas se encuentran enriquecidas en adhesión celular, estructura de la matriz extracelular, procesos de interacción o agregación y variación antigénica, mientras que las proteínas largas contienen dominios hidrolíticos como degradación de componentes celulares, modificación de carbohidratos, remodelación de la pared celular, respuesta inmune, catabolismo de peptidoglucano, turnover de la envoltura celular y procesos tóxicos mediados por ribonucleasas.; no obstante, una proporción importante de microdominios careció de términos GO, especialmente dentro de las familias caracterizadas por regiones repetitivas, lo que nos subraya la necesidad de ampliar las ontologías y validar experimentalmente estas funciones desconocidas.

Abstract

Animal microbiota secrete proteins that act as signaling molecules or effectors, modulating host processes such as immunity, development, and longevity. However, the functional annotation of these proteins remains inadequate because homology-based methods have low sensitivity in detecting microdomains and short motifs. To address this deficiency, a representative set of 22 bacterial secreted proteins with experimental evidence was selected. Through an integrative workflow, additional microdomains were detected using tools such as InterProScan and ScanProsite, and structural models were generated using AlphaFold2. Furthermore, Gene Ontology (GO) terms were retrieved for each protein, allowing for the evaluation of functional enrichment through hypergeometric and Fisher's exact tests, and generating a visualization of functional differences. The analysis revealed that short proteins are enriched in cell adhesion, extracellular matrix structure, interaction or aggregation processes, and antigenic variation, while long proteins contain hydrolytic domains such as degradation of cellular components, carbohydrate modification, cell wall remodeling, immune response, peptidoglycan catabolism, cell envelope turnover, and toxic processes mediated by ribonucleases. However, a significant proportion of microdomains lacked GO terms, especially within families characterized by repetitive regions, which underscores the need to expand ontologies and experimentally validate these unknown functions.

Palabras clave

Microdominios, proteínas secretadas, microbiota, Bacteria, AlphaFold2, FoldSeek, secretoma bacteriano

Keywords

Microdomains, secreted proteins, microbiome, Bacteria, AlphaFold2, FoldSeek, bacterial secretome

Introducción

La microbiota de los animales puede estar influyendo profundamente en procesos fisiológicos del hospedero, entre los cuales se incluyen el desarrollo inmunitario, la longevidad, la fertilidad y la respuesta al estrés (Walsh et al., 2022). Muchos de estos efectos son mediados por proteínas secretadas por las bacterias simbiotes, las cuales actúan como señales o efectores moleculares en el diálogo (Walsh et al., 2022). Por ejemplo, en el pez cebra *Danio rerio*, la bacteria intestinal *Aeromonas veronii* secreta la proteína AimA, un inmunomodulador que previene la acumulación excesiva de neutrófilos en el intestino y protege tanto al hospedero como a la bacteria de daños (Rolig et al., 2018). Estructuralmente, AimA contiene dos dominios tipo calicina similares a la lipocalina-2 de mamíferos, lo que nos ilustra cómo un factor microbiano puede mimetizar proteínas del hospedero para modular la respuesta (Rolig et al., 2018).

En el nemátodo *Caenorhabditis elegans*, la actividad metabólica de sus bacterias comensales, por ejemplo, la síntesis de folato y vitamina B en *Escherichia coli*, influye directamente en la longevidad del gusano (Virk et al., 2012). Mutantes bacterianos que reducen la producción de folato, o el tratamiento con fármacos que inhiben la vía de folato, extienden la vida media de *C. elegans* sin afectar su nutrición, aliviando un exceso de folatos microbianos que acorta la vida del organismo (Virk et al., 2012). Estos ejemplos demuestran que las proteínas y metabolitos secretados por la microbiota simbiótica pueden modular procesos clave del hospedero, desde la inmunidad intestinal hasta el envejecimiento, resaltando la importancia de caracterizar las funciones moleculares en contextos de simbiosis (McFall-Ngai et al., 2013).

Debido a la alta relevancia de las proteínas secretadas en las interacciones hospedero-microbio, la anotación funcional precisa es una tarea esencial para comprender las bases moleculares de dichas interacciones (Walsh et al., 2022). Tradicionalmente, las funciones proteicas se infieren por homología usando herramientas como BLAST, que realiza alineamientos locales para detectar similitudes significativas o HMMER, que emplea modelos ocultos de Markov para reconocer dominios conservados en secuencias (Baetsen-Young, A., 2019). Estas herramientas han sido esenciales en la bioinformática, pero nos presentan limitaciones importantes. Sin embargo, la identificación de la función de estas proteínas se ve con limitaciones por la dependencia excesiva de métodos de anotación clásicos que se basan únicamente

en similitud de secuencia, como nucleótidos o aminoácidos. Por ejemplo, su sensibilidad disminuye drásticamente al comparar proteínas muy variables evolutivamente, y hay fallas con frecuencia en detectar regiones funcionales cortas o poco conservadas, como motivos lineales, sitios activos o dominios pequeños de menos de 100 aminoácidos (Edwards et al., 2007).

Estas limitaciones metodológicas hacen que estas regiones cortas o variables, no puedan obtener una anotación funcional clara y confiable. Específicamente los microdominios han sido particularmente difíciles de anotar y detectar solamente por métodos de homología. Sin embargo, a pesar de las limitaciones de identificación, encontrar las funciones asociadas es crucial, porque pueden cumplir roles críticos en las interacciones microbio-hospedero. Es por esto, que es necesario tener alternativas de aproximaciones más integrales, que combinen información estructural, secuencial y predicciones en los contextos de secreción, para reconocer las funciones que no aparecen en las anotaciones clásicas.

Como señalan (Skunca et al., 2012), más del 98% de las anotaciones de función en bases de datos como UniProt se infieren automáticamente por similitud, pero muchas de estas predicciones pueden ser poco específicas o pasadas por alto si la proteína de interés carece de homologías. En el caso de proteínas secretadas de las bacterias simbiotes, que usualmente son únicas de su hábitat ecológico, esta dependencia en la homología clásica deja una brecha en el conocimiento: numerosas proteínas que aparecen sin anotación funcional detallada, afectando el entendimiento de las consecuencias hacia su hospedero.

En los años recientes, se ha venido demostrando que integrar la información estructural puede superar algunas de estas limitaciones en la anotación. El uso de métodos avanzados de predicción de estructura tridimensional, como AlphaFold2 (Jumper et al., 2021) y algunos más recientes como ESMFold, basado en modelos de lenguaje, nos permiten obtener modelos estructurales precisos incluso para proteínas sin homologías conocidas (Fujita & Terada 2024) Estas herramientas han revolucionado la biología molecular, al generar modelos que son confiables para millones de secuencias proteicas. De hecho, bases de datos como AlphaFold DB proveen ahora, estructuras predichas para más de 214 millones de proteínas de numerosas (Varadi et al., 2024), cubriendo todo el proteoma de UniProt, incluyendo proteínas hipotéticas, con modelos de alta confianza. Adicionalmente, esfuerzos basados en aprendizaje profundo de escala evolutiva han aportado cientos de millones de modelos para secuencias (Fujita & Terada, 2024).

Es decir, se hace referencia a modelos de aprendizaje de deep learning, que están entrenados con colecciones gigantes de secuencias que codifican para patrones evolutivos. Incluyendo información de conservación, coevolución y relaciones entre las familias proteicas. Cuando los modelos aprenden estas regularidades, se puede hacer una inferencia de estructura o función, incluso para proteínas con homólogos cercanos.

En conjunto, se cree que hay aproximadamente 800 millones de estructuras proteicas predichas públicamente disponibles, un volumen de datos significativo, que nos abre nuevas vías para la anotación funcional basada en estructura. Sin embargo, buscar similitudes en una base de datos de tal magnitud genera un gran desafío computacional. Los algoritmos clásicos de alineamiento estructural, como TM-align, aunque sensibles, son bastante lentos para búsquedas exhaustivas en bases de datos gigantes, que tomarían semanas de cómputo para procesar (Edgar, 2024). En respuesta a esta limitación, (van Kempen et al., 2023) desarrollaron FoldSeek, una herramienta de búsqueda estructural que supera la rapidez de programas similares, codifica las interacciones terciarias de cada proteína en una secuencia de caracteres (van Kempen et al., 2023). Al convertir la estructura 3D en una representación 1D, FoldSeek se aprovecha de algoritmos de búsqueda de secuencias altamente optimizados para comparar estructuras. Esto ha permitido acelerar las búsquedas de estructuras en cuatro a cinco órdenes de magnitud, lo que mantiene una sensibilidad comparable con métodos tradicionales como TM-align (van Kempen et al., 2023). En otras palabras, FoldSeek puede alinear en minutos u horas miles de modelos donde antes se requerirían días, lo que viabiliza explorar rápidamente vecindades estructurales en el espacio proteico predicho.

En paralelo, se han propuesto enfoques basados en aprendizaje automático y deep learning para la predicción de funciones proteicas que no dependen exclusivamente de similitud directa. Modelos de red neuronal profunda pueden integrar múltiples niveles de información; secuencia, estructura, motivos, redes de interacción para inferir la función de una proteína. Un ejemplo reciente es el modelo de Fujita & Terada (2024), que combinó unos descriptores de secuencia primaria, comparaciones de dominios estructurales predichos por AlphaFold2, y características de microdominios, para predecir si dos enzimas catalizan la misma reacción. Este enfoque, que se considera integrativo, superó en exactitud a métodos clásicos basados solo en secuencia y a otros métodos de aprendizaje. Además, el análisis de importancia de características reveló que la similitud de dominios estructurales cortos, fue la variable más influyente para predecir la función (Fujita & Terada, 2024). Esto confirma que estos elementos, aunque pequeños, son muy informativos funcionalmente.

Los microdominios pueden contener suficiente información para predecir una función, incluso en la ausencia de la metodología clásica, algo sumamente importante porque los secretomas bacterianos son abundantes en proteínas cortas o con baja conservación evolutiva. Por lo tanto, el considerar las señales estructurales nos abre la posibilidad de caracterizar las funciones que antes pasaban desapercibidas.

De modo similar, otros trabajos que emplean redes neuronales profundas han logrado avances en la clasificación de funciones, por ejemplo, predicción de términos Gene Ontology, integrando datos de secuencia, estructuras y anotaciones funcionales con descripciones curadas, como términos GO y metadatos (Frimpong et al., 2024). No obstante, el desempeño de estos modelos sigue siendo bajo en ciertos escenarios. En

particular, identificar regiones funcionales pequeñas resulta difícil si no existen suficientes datos experimentales para entrenar los modelos en esas características específicas. Es decir, los algoritmos de aprendizaje pueden pasar por alto señales funcionales breves y poco comunes, especialmente cuando operan en un régimen de aprendizaje de pocos ejemplos. Este sigue siendo uno de los grandes desafíos en predicción de función proteica mediante inteligencia artificial: mejorar la sensibilidad hacia motivos raros o novedosos (Frimpong et al., 2024).

Tradicionalmente, las proteínas pequeñas, aproximadamente menos de 100 aminoácidos, fueron pasadas por alto o descartadas como posibles objetos en los estudios genómicos. Esto se debió en parte a dificultades técnicas: marcos de lectura muy cortos (smORFs) son más difíciles de predecir y validar, y muchas microproteínas no muestran homología clara con proteínas conocidas, por lo cual las estrategias computacionales convencionales solían ignorarlas (Storz et al., 2014). Gisela Storz y colegas observaron que, pese al tamaño reducido, hay una inmensa diversidad de funciones en las microproteínas bacterianas, que pueden actuar como reguladores en membranas, chaperonas solubles, toxinas antisentido, entre otras.

Se han descubierto proteínas cortas bacterianas involucradas en procesos tan variados como la división celular, el transporte de nutrientes, la señalización transductora, la formación de esporas y la degradación de RNA (Storz et al., 2014). Muchas de ellas operan asociadas a membranas, como los péptidos hidrofóbicos, o modulando complejos mayores, ilustrando que el tamaño pequeño no impide un gran impacto funcional. Así, en contra de nociones previas, las proteínas <100 aa abundan y cumplen roles esenciales en la fisiología microbiana (Storz et al., 2014). Su detección y anotación, sin embargo, sigue siendo muy difícil: muchas se encuentran codificadas en regiones anotadas previamente como “intergénicas” o como ARN no codificantes, o requieren experimentos especializados (*p. ej.*, estrategias como “*ribosome profiling*”) una técnica que busca identificar cuáles regiones del ARN mensajero son traducidas para medir los fragmentos que están protegidos por ribosomas, para confirmar su expresión. A nivel de secuencia, pueden carecer de dominios característicos, o contener apenas uno o dos motivos cortos que no alcanzan significancia en búsquedas BLAST/HMMER estándar.

Dentro de las proteínas más grandes, también podemos encontrarnos con segmentos cortos de menos de 100 aminoácidos, conocidos como microdominios o motivos lineales cortos, que median funciones esenciales dentro de la célula. Estos motivos suelen localizarse en regiones desordenadas de la proteína, sirviendo como módulos de interacción o regulación (Edwards et al., 2007). A pesar de consistir en tan solo unos pocos aminoácidos, estos motivos cortos pueden dictar la localización subcelular de una proteína, su unión a un dominio o ser diana de modificaciones postraduccionales, por ejemplo, sitios de fosforilación o ubiquitinación (Edwards et al., 2007). Debido a su tamaño, el mismo motivo puede aparecer independientemente en distintas proteínas no relacionadas, actuando como módulo funcional reutilizable a lo largo de diferentes

vías biológicas. Identificar estos microdominios es un desafío: debido a su corta longitud, hace que aparezcan de forma aleatoria en muchas proteínas y se encuentren falsos positivos, por esto se requieren estrategias bioinformáticas especializadas que combinen búsquedas de patrones, ej., mediante herramientas como ScanProsite (Edwards et al., 2007). Pese a su dificultad, entender la presencia de estos dominios cortos en las proteínas secretadas puede ser revelador, ya que muchos efectores bacterianos explotan estos motivos para interferir en rutas celulares del hospedero como por ejemplo, motivos de internalización que engañan a la célula para absorber toxinas bacterianas.

En este trabajo se explora la presencia y función de microdominios en un conjunto de proteínas secretadas pertenecientes al consorcio microbiano definido asociado a *C. elegans* de CeMbio (Dirksen et al., 2020). Se realiza una propuesta de estrategia integrativa de anotación funcional que combina múltiples herramientas bioinformáticas de libre acceso, incluyendo: anotaciones de base de datos (UniProt), detección de motivos conservados (ScanProsite), búsquedas de similitud estructural (FoldSeek sobre modelos de AlphaFold/ESMFold) y mapeo de términos funcionales (Gene Ontology). Mediante esta integración de datos de secuencia, estructura y predicciones computacionales, se busca superar las limitaciones de los métodos basados solo en secuencia y generar anotaciones más completas y precisas para las proteínas secretadas de origen bacteriano. Por lo que la pregunta central que guía este estudio es: ¿Cuáles regiones funcionales pequeñas se pueden recuperar con métodos basados en estructura y función, integrando datos más allá de la similitud de la secuencia tradicional?.

Teniendo esto en cuenta, el objetivo general del proyecto es validar y comparar las anotaciones funcionales de las proteínas secretadas por bacterias, generadas a partir de enfoques basados en secuencia, estructura y aprendizaje automático, realizando un énfasis en la detección y un análisis diferencial de microdominios en proteínas cortas (<100 aa) y proteínas largas (>100 aa). Para esto, se seleccionó y curó la base de datos, se integraron las predicciones estructurales y se evaluaron a través de modelos de aprendizaje profundo, con esto, se analizó estadísticamente el enriquecimiento funcional para proteínas largas y cortas, buscando identificar patrones para confirmar o desmentir la hipótesis de que las proteínas secretadas cortas pueden recuperarse mediante enfoques que integran la información estructural y los modelos de aprendizaje, en comparación a los métodos tradicionales, basados solamente en homología de secuencia.

Marco teórico y antecedentes

1. Bases moleculares de la secreción bacteriana

Las bacterias han ido desarrollando diversos sistemas de secreción para exportar proteínas a su ambiente extracelular o a los compartimentos específicos, ya que juegan un papel central en la virulencia, la competencia y la simbiosis. En las bacterias Gram-negativas se conocen múltiples tipos de sistemas de secreción especializados

(Tipos I al VII), además de la vía general Sec y la vía de argininas Tat, que también están presentes en Gram-positivas. Cada uno de estos sistemas tiene una mecánica distinta: por ejemplo, los sistemas Tipo I secretan sustratos mediante transportadores ABC de un solo paso; el Tipo II exporta proteínas primero al periplasma vía Sec y luego fuera de la célula; el Tipo III, un sistema de secreción por aguja o injectisoma y el Tipo IV, que es similar a pilus de conjugación, son un tipo que inyectan efectores directamente en células huésped; el Tipo V, los autotransportadores y Tipo Va/b aprovechan Sec para atravesar la membrana interna y luego se autotranslocan por la externa; el Tipo VI funciona como un complejo contráctil similar a fagos para inyectar toxinas; y el Tipo VII, descrito en micobacterias y Gram +, exporta proteínas a través del complejo ESX-1 relacionado con factores de virulencia (Desvaux et al., 2009).

En conjunto, todos estos sistemas de secreción determinan cuáles proteínas alcanzarán el exterior de la bacteria, algo crucial para entender toda la composición del secretoma y el tipo de microdominios que participan en la interacción con el hospedero.

En las bacterias Gram-positivas, monodérmicas, son las que carecen de una membrana externa, predominan la ruta Sec, que es dependiente de péptido señal Sec/SRP y la ruta Tat, translocación de proteínas plegadas, junto con mecanismos como sortasas para anclar proteínas a la pared celular. Por su parte, las Gram-negativas, didérmicas, emplean además los sistemas I–VI mencionados para atravesar la doble membrana. A través de todas estas vías que permiten transportar diversas moléculas como: toxinas, enzimas hidrolíticas, efectores, hacia el exterior o directamente al interior de células eucariotas hospedadoras, facilitando de esta forma la interacción microbiana con el medio y otros organismos (Desvaux et al., 2009).

La identificación de proteínas secretadas, está basada principalmente en detectar las señales peptídicas o características de localización subcelular en sus secuencias. Las proteínas secretadas por la vía Sec convencional suelen poseer un péptido señal en el extremo N-terminal: un segmento de alrededor de 20 a 30 residuos hidrofóbicos con un motivo de corte específico. Herramientas como SignalP (Almagro et al., 2019) se basan en analizar la presencia de estos péptidos señal Sec, mientras que TatP detecta las señales características de la vía Tat. Adicionalmente, predictores de localización subcelular como PSORTb y su base de datos PSORTdb 4.0 integran múltiples señales, péptido señal, motivos de anclaje, patrones de aminoácidos, para asignar una ubicación subcelular probable a proteínas bacterianas, puede ser en el citoplasma, membrana interna, periplasma, membrana externa o extracelular. Sin embargo, es importante destacar que tales predicciones, si bien eficaces para identificar candidatas, no garantizan una anotación funcional completa ni infalible. Muchas proteínas secretadas carecen de señales clásicas, por ejemplo, algunas toxinas se secretan mediante vesículas o mecanismos no canónicos, por lo que es necesario hacer un complemento de la predicción, con métodos experimentales o con anotaciones de dominios funcionales y estructuras para confirmar la localización extracelular real de las proteínas.

2. Microdominios lineales (SLiMs) en proteínas

Además de los dominios convencionales, que tienen aproximadamente >80 aminoácidos, se ha reconocido un papel crítico de los microdominios lineales en la función proteica. Estos microdominios, también son conocidos como motivos lineales cortos o short linear motifs, (SLiMs), que son segmentos de apenas 3 a 15 aminoácidos situados usualmente en regiones desordenadas de las proteínas, que son segmentos de una proteína que no vuelven a adoptar una estructura tridimensional estable, siendo de esta forma, flexibles y dinámicas (Van Roey et al., 2012). A pesar de su tamaño reducido, los SLiMs median interacciones específicas y transitorias con otras macromoléculas, actuando así, como módulos de regulación celular. Estos suelen estar definidos por uno o pocos aminoácidos conservados que constituyen el núcleo funcional del motivo, y están rodeados por posiciones susceptibles a variación. Esta combinación de conservación y flexibilidad permite que el mismo motivo pueda aparecer de forma independiente en proteínas no relacionadas evolutivamente, convergiendo funcionalmente para reclutar las mismas moléculas diana o ejecutar procesos similares. Por ejemplo, muchos motivos lineales sirven como sitios de unión para dominios moduladores, señales de localización subcelular como motivos de anclaje a membrana, secuencias de exportación nuclear o puntos de control postraduccionales: sitios de fosforilación, ubiquitinación, entre otros (Davey et al., 2012).

La identificación computacional de SLiMs es bastante compleja dada su longitud y a que el mismo patrón corto puede ocurrir al azar en muchas proteínas. Existen, sin embargo, variedad de herramientas bioinformáticas diseñadas para buscar varios motivos conservados en secuencias proteicas. ScanProsite, por ejemplo, utiliza la colección de patrones de PROSITE, basada en expresiones regulares, para escanear las secuencias en busca de motivos conocidos. No obstante, dada la abundancia de coincidencias, suele ser necesario filtrar los resultados basándose en conocimiento biológico y aplicar los respectivos análisis estadísticos de sobre-representación para evaluar qué motivos aparecen significativamente más de lo esperado al azar. Por esta razón, muchos pipelines de anotación de SLiMs incorporan criterios evolutivos, como presencia en ortólogos y métodos estadísticos para distinguir motivos funcionales verdaderos de secuencias fortuitas (Davey et al., 2012). En conjunto, el estudio de microdominios lineales ofrece una ventana hacia interacciones reguladoras sutiles pero importantes, que complementan la información proporcionada por los grandes dominios en las proteínas.

3. Microproteínas bacterianas

Paralelamente, al estudio de los motivos cortos, la investigación ha comenzado a iluminar el mundo de las microproteínas, definidas usualmente como polipéptidos de menos de 100 aminoácidos. Durante un largo tiempo, como se mencionó anteriormente, este tipo de proteínas, fueron pasadas por alto por los métodos de anotación y consideradas rarezas o artefactos, debido a que sus genes, provenientes de

smORFs, por sus siglas en inglés, que son marcos de lectura pequeños, a menudo no eran detectados en la predicción génica convencional o se descartaron por no tener homólogos conocidos (Storz et al., 2014). Sin embargo, las técnicas como *ribosome profiling* y la proteogenómica han revelado que las microproteínas que constituyen un buen porcentaje de los proteomas bacterianos, se estima entre un 5 % y 10 % de los genes en algunos organismos codifican péptidos ≤ 100 aa (Miravet-Verde et al. 2019).

Estos hallazgos son bastante relevantes para el campo, porque nos indica que gran parte de la abundancia de micro proteínas y péptidos, que son una parte significativa de las funciones bacterianas, han permanecido ocultas para los modelos clásicos de anotación. Estas proteínas, al tener pocos dominios grandes o estructuras terciarias bien definidas, pueden modular procesos clave, influyendo en rutas metabólicas o participando en procesos simbióticos. Por esto, al comprender la presencia y caracterización, se capturan fragmentos mínimos, pero muy informativos.

Muchas de las microproteínas desempeñan funciones regulatorias clave. Por ejemplo, en bacterias Gram-positivas se han identificado micro proteínas que modulan la esporulación, p. ej. SpoVM y Sda en *Bacillus subtilis*, controlan la actividad de proteasas esenciales como FtsH, o actúan como subunidades adaptadoras en complejos de membrana. En otros ejemplos, se han podido observar microproteínas bacterianas, que se han asociado a la regulación de la traducción, la respuesta al estrés y la formación de biopelículas (Rudner et al., 2023). Dado su tamaño, muchas microproteínas carecen de estructuras terciarias complejas y pueden estar intrínsecamente desordenadas o formar un único pliegue pequeño. Esto las hace sumamente dinámicas, permitiéndoles unirse a blancos más grandes o servir de “tapones” moleculares que bloquean sitios activos.

Debido a esto, es evidente que es necesario dar un enfoque diferente en la anotación para detectar estas funciones claves. El tamaño reducido, la frecuencia de regiones desordenadas y la carencia de motivos largos conservados, generan que las herramientas no puedan detectar la señal funcional. Las nuevas aproximaciones permiten identificar funciones regulatorias que pueden ser sutiles, a pesar de las limitaciones por su longitud.

Ajustar los algoritmos de búsqueda de ORFs y validar que realmente se expresan y cumplen una función, es el camino claro. No obstante, el aumento del catálogo de microproteínas en microbiomas indica que muchas están conservadas evolutivamente y probablemente varias de estas cumplen roles adaptativos importantes (Duan et al., 2024). Por ejemplo, un esfuerzo reciente construyó un catálogo de casi mil millones de smORFs a partir de metagenomas de diversos hábitats, revelando que un subconjunto significativo codifica micro proteínas con dominios funcionales o motivos conservados, implicadas en vías señalizadoras y de defensa. Estos hallazgos resaltan la necesidad de incorporar estrategias específicas para anotar microproteínas en los análisis funcionales, ya que podrían pasarse por alto por métodos enfocados solo en proteínas convencionales más largas (Gálvez et al., 2024).

4. Anotación funcional y bases de datos bioinformáticas

Para inferir la posible función de una proteína, ya sea secretada o no, es fundamental apoyarse en bases de datos de dominios y anotaciones funcionales. Herramientas ampliamente utilizadas como Pfam e InterPro asignan dominios conocidos a una secuencia proteica mediante la búsqueda de perfiles característicos. Pfam, por ejemplo, recopila más de 18 000 familias de proteínas representadas por HMMs y logra cubrir alrededor del 77 % de las secuencias de los proteomas de referencia en UniProt (Mistry et al., 2021). InterPro, por su parte, integra múltiples bases de datos: incluyendo Pfam, PROSITE, SMART, entre otras, proporcionando un buen panorama consolidado de las regiones funcionales presentes en la proteína (Jones et al., 2014). Estas herramientas permiten detectar dominios de un tamaño mediano a grande con alta sensibilidad. Sin embargo, tenemos huecos notables en la anotación de elementos pequeños: las familias de proteínas muy cortas, los dominios poco comunes y los microdominios lineales suelen estar subrepresentados o directamente ausentes en Pfam/InterPro. Por esto, se han desarrollado recursos complementarios enfocados en patrones cortos y señales poco convencionales.

Adicionalmente, para describir la función biológica de una proteína de manera estandarizada se emplean ontologías controladas como la Gene Ontology (GO). GO clasifica los atributos de los genes/proteínas en tres grandes categorías jerárquicas: proceso biológico, función molecular y componente celular. Cada proteína puede recibir múltiples términos GO que describen su rol. Por ejemplo, “hidrolasa de peptidoglicano”, “unida a membrana externa”, “respuesta a estrés oxidativo”. Estos términos se organizan en una estructura de grafo acíclico dirigido (DAG), donde un término puede ser subtipo de otro más general. Las bases de datos como UniProtKB proporcionan anotaciones GO automáticas basadas en homologías y dominios, respectivamente (Gene Ontology Consortium, 2021). De esta forma, una vez se identifican los dominios en una proteína, se pueden inferir sus posibles funciones y procesos asociados mediante mapeo a GO. No obstante, para interpretar correctamente las anotaciones GO de un conjunto de proteínas resulta necesario aplicar análisis estadísticos que determinen cuáles funciones están enriquecidas o sobrerrepresentadas con respecto a lo esperable por azar en el contexto del genoma o proteoma completo. A continuación, se describen los métodos estadísticos comúnmente empleados para dicho fin.

5. Métodos estadísticos para el enriquecimiento funcional

La evaluación del enriquecimiento funcional busca identificar diferentes categorías, tales como: términos GO, rutas metabólicas, familias de dominios, que aparecen con frecuencia inusualmente alta en un conjunto de proteínas de interés, comparado contra un trasfondo de referencia. El enfoque más común es el análisis de sobre-representación, que puede modelarse como un problema de muestreo hipergeométrico. En este modelo, dada una categoría funcional específica, por ejemplo,

“respuesta a estrés oxidativo”, se tienen: N proteínas en el universo, siendo este, el total de proteínas con anotaciones consideradas, de las cuales M pertenecen a dicha categoría en la base de conocimiento; luego, en nuestro conjunto de estudio de tamaño n , observamos que k de ellas están anotadas con esa categoría (Falcon & Gentleman, 2007). Bajo la suposición nula de distribución aleatoria, la probabilidad de observar k o más proteínas de la categoría en un conjunto de tamaño n viene dada por la distribución hipergeométrica:

$$P(X \geq k) = \sum_{i=k}^n \frac{\binom{M}{i} \binom{N-M}{n-i}}{\binom{N}{n}},$$

donde los coeficientes binomiales cuentan las maneras de escoger i proteínas de las M de la categoría y $n-i$ de las $N-M$ restantes. Este valor P unilateral, indica la significancia de que al menos k proteínas de la categoría aparezcan en el conjunto dado su prevalencia de fondo (Falcon & Gentleman, 2007). En la práctica, suele emplearse el equivalente test exacto de Fisher, que es una prueba exacta para tablas de contingencia 2×2 , para calcular esta probabilidad de forma precisa, especialmente cuando los conteos son pequeños. Un p -valor bajo sugiere que la categoría está sobrerrepresentada en el conjunto de interés más allá de lo esperado al azar, implicando una posible señal biológica significativa.

Una vez identificadas las funciones enriquecidas, es común representarlas visualmente mediante volcano plots, gráficas que muestran, en el eje x, la magnitud del efecto y en el eje y la significancia estadística ($-\log_{10}$ del p -valor). Las categorías más relevantes aparecen como puntos “destacados” en la gráfica, debido a su significancia y efecto. Otra visualización útil son los bubble plots, donde cada burbuja corresponde a un término funcional, cuya posición puede indicar enriquecimiento y magnitud del efecto, el tamaño de la burbuja refleja el número de proteínas involucradas, y el color codifica el p ajustado (Yu et al., 2012). Estas herramientas ayudan a sintetizar los resultados del análisis de enriquecimiento de forma intuitiva.

Dichos enfoques pueden mejorar la interpretación biológica al evitar redundancias (Yu et al., 2012). En cualquier caso, la aplicación cuidadosa de estas pruebas estadísticas, junto con una interpretación experta, permite derivar hipótesis funcionales sólidas a partir de listas de proteínas, conectando los datos obtenidos con conocimiento biológico de alto nivel.

8. Antecedentes del proyecto y enfoques previos

Recientemente se han desarrollado recursos genómicos específicos para estudiar la microbiota de *C. elegans*. En particular, el recurso CeMbio (Dirksen et al., 2020) compiló un consorcio de 12 bacterias representativas del microbioma nativo de *C.*

elegans, con sus genomas completamente secuenciados y anotados. CeMbio ha sido empleado para caracterizar la dinámica y composición de la microbiota del nematodo, revelando que ésta muestra estabilidad geográfica y, a la vez, una considerable diversidad funcional entre sus miembros (Dirksen et al., 2020). Contar con este conjunto ya definido de genomas facilita enormemente los análisis funcionales, ya que proporciona un universo acotado y relevante ecológicamente de secuencias para examinar.

En el grupo de investigación que sustenta este trabajo, se llevó a cabo un estudio previo enfocado en la microbiota asociada al organismo modelo *C. elegans* que sirvió de base para el presente trabajo de grado. En dicho trabajo se predijeron proteínas potencialmente secretadas por varias bacterias cultivables de la microbiota del nematodo, utilizando los predictores computacionales mencionados (SignalP, TatP, PSORTb) sobre los genomas bacterianos disponibles. Se tomaron en cuenta diferencias entre bacterias monodérmicas y didérmicas, caracterizando para cada cepa las vías de secreción plausibles y las localizaciones subcelulares previstas de sus proteínas secretadas. Este análisis preliminar, generó un conjunto inicial de proteínas secretadas candidatas por los microorganismos asociados a *C. elegans*. Dicho conjunto se trata del punto de partida de la presente investigación, que busca enriquecer su anotación funcional mediante la integración de enfoques basados en secuencia, estructura y aprendizaje automático. Es decir, a partir del “secretoma” predicho de la microbiota del nematodo, el objetivo ahora es profundizar en qué funciones podrían desempeñar esas proteínas en la interacción y descubrir elementos funcionales que pudieran haber pasado inadvertidos en la anotación que se ha realizado convencionalmente.

Los estudios previos en otros sistemas de simbiosis respaldan la relevancia de esta aproximación. Como ya se discutió, la identificación de proteínas bacterianas secretadas ha revelado con frecuencia factores moduladores del hospedero en distintos modelos. En *C. elegans*, la simple presencia o ausencia de ciertas funciones bacterianas secretadas, como la síntesis de folato, de vitaminas, degradación de compuestos tóxicos, etc. que puede prolongar o acortar la vida del nemátodo y alterar su fisiología (Virk et al., 2016). Sin embargo, hasta la fecha no existía un estudio exhaustivo que analizara de forma integral un conjunto seleccionado computacionalmente de proteínas secretadas de la microbiota bacteriana, con especial énfasis en sus dominios cortos y motivos funcionales. Este vacío en la literatura representa una oportunidad para descubrir nuevos mecanismos moleculares de la interacción animal-microbiota.

En conjunto, las observaciones nos sugieren que todavía falta descubrir de una forma sistemática, cuáles funciones podrían estar escondidas bajo los microdominios o proteínas cortas secretadas por la microbiota asociada a *C. elegans*. A pesar del catálogo actual y las predicciones, falta realizar una evaluación exhaustiva de la anotación de forma integrada. La ausencia de esto no hace posible la correcta interpretación del secretoma bacteriano y dificulta identificar funciones moduladoras

claves. Es por esto, que abordar el vacío mediante herramientas que complementan la anotación, genera oportunidades de revelar funciones que antes pasaban inadvertidas.

Metodología




Figura 1. Marco conceptual del flujo de información para la predicción funcional de proteínas secretadas dependiente de la longitud. El esquema ilustra las etapas principales del pipeline analítico: (i) adquisición y filtrado de proteínas secretadas desde UniProtKB (The UniProt Consortium, 2023) según taxonomía, evidencia experimental a nivel de proteína, transcrito y homología; (ii) validación y caracterización por anotaciones de secuencia y motivos; (iii) integración de predicciones estructurales obtenidas, (iv) separación de proteínas en dos grupos según longitud (<100 aa y >100 aa) y asignación de microdominios detectados. El esquema representa la progresión desde la base de datos hasta la clasificación funcional final.

1. Recopilación y curación de datos

La construcción de un conjunto de referencia de proteínas secretadas bacterianas constituyó el primer objetivo de este estudio. Se utilizó como principal fuente la base de datos UniProtKB (versión 2025_03). Las búsquedas se restringieron al dominio Bacteria utilizando el identificador taxonómico OC=2 y el filtro de localización subcelular Secreted (código SL-0243) de UniProt. Adicionalmente, se aplicaron tres niveles de Protein Existence (PE), evidencia a nivel de proteína, a nivel de transcrito e inferido por homología, con la condición de que las anotaciones tuvieran respaldo experimental, esto aseguró la inclusión de proteínas realmente secretadas y con algún nivel de caracterización funcional.

Las consultas se realizaron individualmente para cada nivel de PE y se combinó el filtro “Reviewed” para privilegiar secuencias con curación manual, en la selección de

homology “any”. En el campo de dominios se utilizó el operador comodín “*” para recuperar todas las anotaciones disponibles, independiente de su categoría. Esta decisión buscó maximizar la cobertura del secretoma e incluir tanto proteínas bien caracterizadas como hipotéticas. Después de la búsqueda, se exportaron los resultados en formato .xlsx para su curación y en formato FASTA para su procesamiento posterior.

1.1 Selección de variables y limpieza de datos

Las columnas exportadas se personalizaron mediante la opción “*Customize columns*” de UniProt para garantizar consistencia en los datos. Se incluyeron variables de identificación (Entry, Entry name, nombres de la proteína y del gen, organismo y Taxonomic ID), estado de revisión (Reviewed), nivel de existencia de la proteína (Protein existence), fecha de creación y última modificación, así como atributos de la secuencia (longitud en aminoácidos y masa teórica). En la sección “Family & Domains” se habilitaron los campos Domain [CC] y Domain [FT], motif, region, repeat, protein families y zinc fingers. El campo Domain [CC] contiene anotaciones curatoriales sin coordenadas, mientras que Domain [FT] agrupa regiones con coordenadas precisas derivadas de predicciones computacionales, a menudo acompañadas de códigos ECO que describen el tipo de evidencia (Sigrist et al., 2012).

Con los datos descargados, se procedió a la curación manual. Se eliminaron entradas duplicadas e incompletas y se verificaron inconsistencias entre campos. Se incorporó una columna adicional para clasificar las variables según su naturaleza, categóricas, numéricas o textuales. Además, se revisaron aleatoriamente varias fichas completas de UniProt para corroborar que la etiqueta “*Secreted*” coincidiera con evidencias experimentales en los registros inferidos por homología. Este procedimiento reveló que algunas proteínas clasificadas como Inferred from homology poseían evidencias experimentales en dominios o localizaciones específicas, lo que subraya la importancia de integrar diferentes niveles de anotación.

1.2 Categorización por tamaño

Una vez curado el conjunto, se clasificaron las proteínas según su longitud en dos grupos: cortas (≤ 100 aminoácidos) y largas (> 100 aa). Esta clasificación siguió la definición de microproteínas propuesta en literatura reciente y permitió evaluar si las proteínas pequeñas portan microdominios con funciones específicas. Para cada categoría se crearon subcarpetas (short_domains y long_domains) que contenían: (i) las secuencias FASTA; (ii) una tabla Excel con la lista de dominios; y (iii) un archivo de texto con metadatos resumidos. Estas carpetas se generaron mediante un script en Python disponible en el repositorio secretome-annotation-pipeline-DAP: <https://github.com/dani-ardila/secretome-annotation-pipeline-DAP> (Ardila, 2025) que vincula las entradas de la hoja Excel con sus secuencias FASTA y organiza los resultados.

Tras obtener los conjuntos de proteínas cortas y largas, con sus respectivos dominios, del secretoma del dominio Bacteria. Se realizó una depuración de duplicados o secuencias sin respaldo experimental que entraron por error, eliminando resultados poco confiables. Posteriormente, se hizo una elección de 22 dominios de proteínas secretadas que cumplieran con los criterios del estudio, 11 entradas para proteínas cortas (<100 aa) y 11 para proteínas largas (>100 aa). Esto se realizó con el fin de evaluar las posibles diferencias asociadas al tamaño, el set de datos fue seleccionado con taxones similares (*Streptomyces*, *Mycobacterium*, *Achromobacter*) de cada conjunto, constituyendo los sets de referencia para los análisis posteriores.

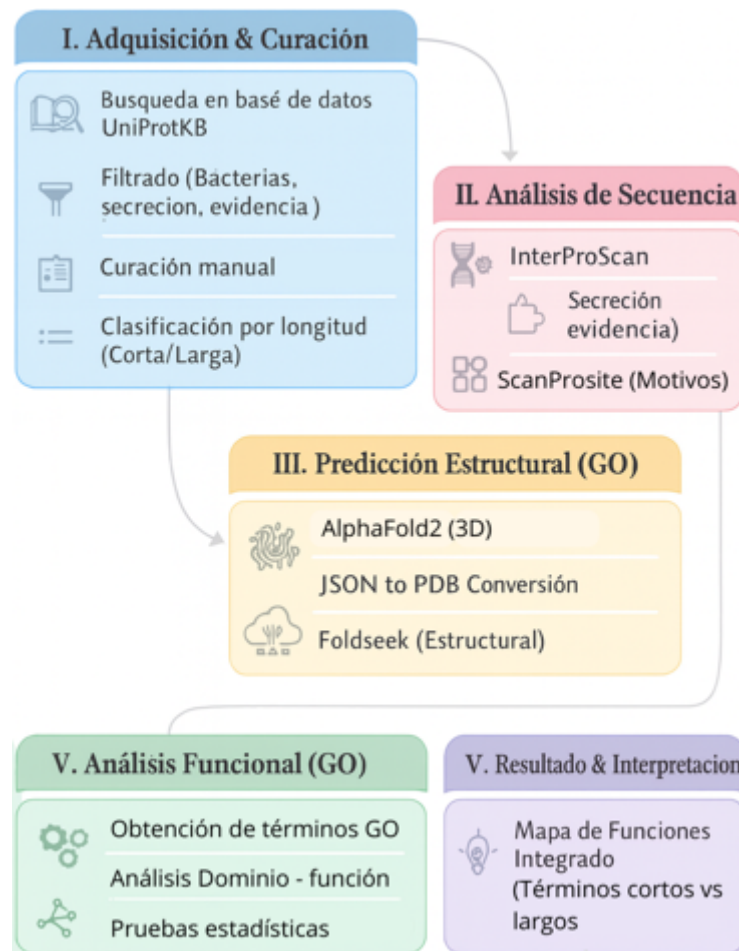


Figura 2. Diagrama de flujo general del flujo metodológico empleado en este estudio, en el que se incluyen cinco paneles. (I) adquisición y curación de la base de datos mediante búsqueda en UniProtKB (The UniProt Consortium, 2023), (II) análisis de secuencia con InterProScan (Jones et al., 2014) para la identificación de dominios y con ScanPrositate (Edwards et al., 2007) para la detección de motivos; (III) predicción estructural utilizando AlphaFold2 (Jumper et al., 2021) y comparación mediante Foldseek (van Kempen et al., 2023), (IV) análisis funcional basado en la recuperación de términos GO, asignación dominio-función y pruebas estadísticas de enriquecimiento. Finalizando con el (V) integración e interpretación de resultados para construir un mapa funcional del secretoma analizado.

2. Detección de microdominios y análisis de secuencia

El segundo objetivo consistió en identificar microdominios y motivos cortos conservados. Para ello se aplicaron herramientas complementarias que integran bases de datos especializadas y patrones definidos.

2.1 Anotación con *InterProScan*

Se empleó InterProScan (release 101.0) para realizar una anotación exhaustiva de dominios y familias. InterPro integra firmas predictivas de múltiples miembros (Pfam, PROSITE, entre otros) y selecciona dominios representativos para maximizar la cobertura y minimizar superposiciones (Blum et al., 2024). Cada FASTA del conjunto se analizó con la versión en línea de InterProScan, y se registraron para cada proteína los dominios asignados, la base de datos de origen, la posición inicial y final y el código de evidencia.

2.2 Búsqueda de motivos con *ScanProsite*

Para complementar la anotación de dominios se utilizó ScanProsite, una herramienta que permite escanear secuencias contra patrones PROSITE. PROSITE identifica regiones conservadas mediante dos tipos de firmas: perfiles generalizados (weight matrices) y patrones definidos mediante expresiones regulares (Sigrist et al., 2012). Estos patrones están vinculados a reglas de anotación ProRule que especifican condiciones para asignar funciones como sitios catalíticos o de unión. El análisis se ejecutó con la base de datos PROSITE release 2023_02 en modo exhaustivo.

3. Predicción estructural y comparación por homología

3.1 Preparación de secuencias y acceso a la API de NVIDIA

Lo que necesitas es un “runner” que:

lea FASTA multi-seq (471)

envíe cada secuencia como job

guarde el JSON/PDB con nombre {entry}

si ya existe, lo salte

al final, recorte dominios en batch

```
Carpeta sugerida

bash

project/
  inputs/
    proteins_full.fasta
    domains.tsv
  predicciones/          # 471 pdb/json
  domains_pdb/           # 1050 pdb
  links/
    links_domains.tsv
```

Para validar y contextualizar los microdominios tridimensionalmente se generaron modelos de estructura para todas las proteínas. Se implementó un entorno de análisis en Google Colab para alojar los archivos en una carpeta denominada Estructuras_Proteinas_NLS en Google Drive: [AlphaFold2.ipynb](#). Mediante comandos de *bash*, se exploró entre carpetas correspondientes a cada bacteria, garantizando una organización lógica. Las secuencias FASTA fueron obtenidas de las subcarpetas generadas previamente con los dominios.

La predicción de estructuras se realizó utilizando la API de NVIDIA para AlphaFold2 (NVIDIA & DeepMind, 2024), que permite generar modelos sin necesidad de plantillas. Para cada secuencia se elaboró un script en Python con las siguientes características:

1. Solicitud de clave API: Se solicitó una Run Key a la plataforma build.nvidia.com/deepmind/alphafold2 y se incluyó en la variable de entorno `NVCF_RUN_KEY`.
2. Entrada de la proteína (Entry): Se pidió al usuario el identificador UniProt (ej. A0A2K6V5L6). Este valor se generó mediante expresiones regulares y se utilizó para nombrar los archivos resultantes.
3. Envío de secuencia: La secuencia de aminoácidos se introdujo en el campo `sequence`.
4. Solicitud inicial y sondeo: El script envió la solicitud a la URL https://build.nvidia.com/deepmind/alphafold2?snippet_tab=Python. Si el servidor respondía con código 202, se extraía el identificador de la petición (`nvcf-reqid`) y se sondeaba periódicamente la URL de estado para obtener el resultado final.

5. Almacenamiento del resultado: Cuando el servidor respondía con código 200, el modelo se almacenaba como un archivo .json dentro de la carpeta predicciones. Véase Anexo. *Tablas y figuras dominios secretados*, disponible en: <https://docs.google.com/document/d/1jXj6BOhtYn4lwMKV8JPO-U3sTEvAzfzdZyF8wUl-Ky4/edit>. Figura 6.

3.2 Conversión a formato PDB

Cada modelo estructural se transformó a formato PDB mediante un código escrito en Python que usa las librerías (*os*, *time* y *pathlib.Path*; Python Software Foundation, 2024) y *requests* (Reitz & Contributors, 2024). Cada modelo se visualizó con la herramienta RCSB PDB (Burley et al., 2024), las opciones de parámetro fueron la solicitud nuevamente del Entry de la proteína, para identificar los archivos para abrir el archivo .json y cargar la lista de líneas y escribir cada línea en un archivo .pdb con el mismo nombre de la proteína. Este procedimiento tuvo unos tiempos de generación para cada estructura de aproximadamente 7 minutos, variables según la longitud de la proteína y la disponibilidad de la API.

3.3 Búsqueda estructural con FoldSeek

Al ser generados los modelos PDB, se procedió a compararlos con estructuras conocidas para identificar homologías y validar la presencia de dominios conservados. Para ello, se utilizó FoldSeek (van Kempen et al., 2023), una herramienta que codifica las interacciones terciarias de las proteínas en secuencias sobre un alfabeto de 20 símbolos (3Di). Este enfoque nos permite realizar búsquedas de homología estructural hasta 10^4 veces más rápido que métodos clásicos (van Kempen et al., 2023). La búsqueda se realizó contra AFDB50, una versión curada de la base de datos sobre la cual fue entrenada AlphaFold, que agrupa proteínas con al menos un 50 % de identidad de secuencia (Szczerbiak et al., 2025). Para cada consulta se obtuvieron alineamientos, puntuaciones de similitud y valores de significancia. Los resultados permitieron determinar si los microdominios detectados en el análisis de secuencia correspondían a regiones estructuralmente conservadas.

4. Anotación funcional mediante Gene Ontology (GO)

4.1 Recuperación de términos GO

En paralelo a las anotaciones de dominios y motivos, se llevó a cabo la anotación funcional clásica utilizando la clasificación de Gene Ontology (GO; The Gene Ontology Consortium, 2021).. Para cada una de las 22 proteínas se recuperaron todos los términos GO anotados en UniProt, clasificados en tres ontologías: Biological Process, Molecular Function y Cellular Component. Las anotaciones provenían de diversas fuentes; varias proteínas carecían de evidencia a nivel de proteína

experimental directa, por lo que se aceptaron términos inferidos por homología y asociados a dominios caracterizados.

Se compiló un archivo, donde cada fila contiene el identificador UniProt, el término GO, la evidencia y referencias. Este archivo sirvió como matriz base para análisis posteriores.

4.2 Construcción de la matriz de contingencia y asociación de dominios

Para analizar la distribución de funciones entre proteínas cortas y largas se construyó una matriz de contingencia de dimensiones 35×2 . Cada fila representaba un término GO y cada columna uno de los grupos de proteínas. Las celdas indican el número de proteínas del grupo anotadas con el término en cuestión. Adicionalmente, se creó una tabla maestra que vincula cada dominio o microdominio identificado con sus términos GO correspondientes. Para ello, cada fila de la tabla incluye: (i) el identificador de la proteína; (ii) la clasificación por longitud; (iii) la categoría funcional; (iv) los dominios detectados (de InterProScan, PROSITE o FoldSeek); y (v) la lista de términos GO asociados.

4.3 Estadísticas de enriquecimiento

Para comparar la distribución de términos GO entre proteínas cortas y largas se aplicaron pruebas de sobrerrepresentación. En primer lugar, se definió el set de referencia dado por todas las proteínas secretadas bacterianas seleccionadas de la base de datos extraída; en total de este conjunto se tomaron 27 términos GO anotados en 22 proteínas secretadas, se estimó la frecuencia esperada de cada término GO. Posteriormente se aplicó una prueba hipergeométrica (Johnson, Kotz, & Kemp, 2005), donde se calculó la probabilidad de observar el número de proteínas anotadas con un término GO dentro del grupo de interés (corto o largo) dado el total de proteínas analizadas y la frecuencia global del término. Posteriormente, se realizó una prueba exacta de Fisher con base en tablas 2×2 para cada término GO (presencia/ausencia vs. pertenencia al grupo) y se calculó un valor p exacto.

Para controlar el error por múltiples comparaciones se aplicó el procedimiento de Benjamini–Hochberg, que controla la tasa de falsos descubrimientos (FDR). El nivel de FDR se fijó en 0,05. Las pruebas se implementaron en R (versión 5.2) con la función *p.adjust* (R Core Team, 2023).

4.4 Visualización de patrones funcionales

Los resultados de las pruebas se visualizaron mediante diferentes gráficos generados con R (versión 5.2), paquetes *tidyverse*: (Wickham et al., 2019; versión 2.0.0), *ggplot2* (Wickham, 2016; versión 3.4.4), *igraph* (Csardi & Nepusz, 2006; versión 1.5.1) y *ggraph* (Pedersen, 2024; versión 2.1.0). Los resultados de enriquecimiento funcional se

visualizaron mediante un (gráfico de volcán, de burbujas y barras apiladas; Wickham, 2016)

5. Implementación computacional y reproducibilidad

5.1 Entornos de programación y dependencias

Todas las etapas del análisis se llevaron a cabo en ambientes reproducibles. Para el procesamiento de secuencias y detección de motivos se empleó Python 3.12 con los paquetes *Biopython* (Cock et al., 2009; versión 1.83), *pandas* (pandas development team, 2020; pandas 2.1.4), y *SciPy* (Virtanen et al., 2020; versión 1.11.4). La comunicación con la API de NVIDIA se implementó mediante la biblioteca *requests* (Reitz & Contributors, 2024).

5.2 Disponibilidad de datos y flujo de trabajo

Los scripts y notebooks están depositados en el repositorio de GitHub secretome-annotation-pipeline-DAP:

<https://github.com/dani-ardila/secretome-annotation-pipeline-DAP> y en Zenodo: <https://doi.org/10.5281/zenodo.17773537> como material suplementario. Cada archivo incluye instrucciones de ejecución y las dependencias necesarias. Se documentó el flujo de trabajo, para Python y en scripts en R, de modo que todos los pasos, desde la descarga de datos hasta la generación de figuras, puedan reproducirse de manera independiente. Para garantizar la transparencia, los resultados intermedios (tablas Excel, archivos FASTA, modelos PDB) se depositaron junto con los scripts.

Todas las variables incluidas en el dataset fueron identificadas directamente a partir de los campos disponibles en UniProtKB. Ver anexos, Tablas y figuras dominios secretados. véase Anexo, *Tablas y figuras dominios secretados*, disponible en: <https://docs.google.com/document/d/1jXj6BOhtYn4lwMKV8JPO-U3sTEvAzfzdZyF8wUl-Ky4/edit>.

5.3 Consideraciones de reproducibilidad y ética

El estudio se diseñó para asegurar la reproducibilidad. Las bases de datos utilizadas son de acceso público, y todas las herramientas empleadas son de código abierto. Se respetaron las licencias correspondientes de cada software. No se procesaron datos personales ni se requirió aprobación ética para el uso de secuencias bacterianas. La implementación del análisis en notebooks y la publicación del código permiten que futuros investigadores apliquen esta metodología en otros contextos, como secretomas de diferentes microbiomas o análisis de microproteínas en genomas eucariotas.

Resultados

La búsqueda realizada en UniProtKB, restringida al dominio taxonómico Bacteria (OC=2) y filtrada por la localización subcelular SL-0243 (Secreted), permitió obtener un total de 671 proteínas secretadas con evidencia experimental en al menos una de sus características anotadas. Los tres niveles de evidencia seleccionados bajo el campo Protein Existence (PE) mostraron la siguiente distribución:

Tabla 1. Distribución de proteínas secretadas según el nivel de evidencia (Protein Existence, PE) reportado en UniProtKB.

Nivel de evidencia (PE)	Registros
Evidence at protein level	304
Evidence at transcript level	36
Inferred from homology - Experimental	48
Inferred from homology - Any - Domain - Reviewed	283

El predominio del grupo *Evidence at protein level* (45,30%) e *inferred from homology en Any* con dominios revisados (42,17%) refleja que la mayoría de las proteínas incluidas cuentan con validación experimental directa o indirecta, mientras que los conjuntos *transcript level* (5,36%) e *inferred from homology* a nivel experimental (7,17%) representan fracciones menores.

En el análisis de las anotaciones estructurales, se observó que todas las proteínas presentaron al menos una anotación en el campo Domain [FT], lo cual coincide con la aplicación del filtro Domain = “*”. No obstante, solo una parte de los registros incluyó anotaciones adicionales en otras categorías estructurales: 117 proteínas (30.2 %) con comentarios curatoriales en Domain [CC], 162 con regiones estructurales definidas, 39 con repeticiones, y 28 con motivos específicos. Ninguna proteína presentó descriptores de zinc fingers.

Tabla 2. Frecuencia y porcentaje de los distintos tipos de anotación secuencial (Domain [FT], Domain [CC], Protein families, Region, Repeat y Motif) identificados en el conjunto de proteínas secretadas.

Tipo de anotación estructural	Registros	Porcentaje (%)
Domain [FT]	388	100
Domain [CC]	117	30,2

Protein families	289	74,5
Region	162	41,8
Repeat	39	10,1
Motif	28	7,2
Zinc finger	0	0

En cuanto a las características de secuencia, la longitud de las proteínas del conjunto presentó una alta variabilidad, con valores que oscilan entre 63 y 4558 aminoácidos, y una media de 706 residuos. Este conjunto de datos se dividió en proteínas cortas (< 100 aa) y largas ($\geq$ 100 aa) para evaluar el rendimiento diferencial del modelo de predicción funcional en función del tamaño de la secuencia.

Análisis de proteínas cortas ($\leq$ 100 aa) y largas ($>$ 100)

El grupo de proteínas cortas ($\leq$ 100 aa) incluyó 11 entradas con microdominios bien definidos (longitud del dominio entre 41 y 93 aa). Cinco de estas proteínas corresponden a chaplin de *Streptomyces coelicolor* (Q9AD92, Q9KYG7, Q9L1J9, Q9X9Z2, Q9KYH3), una a un ACP *Acyl Carrier Protein*, secretado de *Brachyspira hyodysenteriae* (O34163) y otra a una cadena pequeña (Protease) de *Achromobacter lyticus* (P81719). Las cuatro restantes pertenecen a la familia PE, proteínas características del phylum *Actinobacteria*, que reciben el nombre por Pro-Glu (PE) o Pro-Pro-Glu (PPE) en el extremo N-terminal de la proteína (Banu et al., 2002) los dominios que corresponden a esta proteína en nuestros conjunto datos, pertenecen al taxón *Mycobacterium tuberculosis* (P9WIG7, Q79FR5, Q79FR3), las funciones anotadas que se encuentran son adhesión celular y respuesta inmune. En todos los casos, el dominio analizado se localiza dentro de la región C-terminal o central de proteínas muy cortas (longitud total entre 63 y 100 aa) y está respaldado mayoritariamente por “Evidence at protein level”.

A diferencia del grupo de las proteínas cortas, el grupo de proteínas largas ($>$ 100 aa) mostró una mayor diversidad en cuanto a funciones. Para *S. coelicolor* se seleccionaron dos proteínas secretadas con dominios anotados (O53289, P07883), ambas con longitudes totales de 259 y 309 aa, respectivamente, y dominios individuales de 41 y 277 aa, los cuales estuvieron relacionados con la hidrólisis de carbohidratos (GH16) y fosfatasas metabólicas (HAD/PSP). Para *M. tuberculosis* se incluyeron siete proteínas, para las cuáles se evaluaron los dominios (O07783, O53168, L0T2H7, Q79FU0, Q79FB3, I6Y8K5) que cubren diferentes tipos de evidencia: desde “Evidence at protein level” hasta anotaciones basadas en homología o nivel de transcrito. Se presentan dominios NlpC/P60 y PIN/VapC, relacionados con virulencia, remodelación del peptidoglicano y potencial de una actividad tóxica dependiente de metales. Finalmente, para *A. lyticus* se seleccionaron dos proteínas secretadas de mayor longitud (P15636, P81717; 653 y 177 aa, respectivamente), cada una con uno o dos

microdominios anotados de entre 80 y 99 aa, con dominios PKD y Amidase_2, muestran una participación en degradación de componentes extracelulares y captación de peptidoglicano. En este grupo, todas las proteínas presentan longitud total >130 aa, asegurando un contraste claro con el conjunto de proteínas cortas.

Relación de anotaciones funcionales derivadas de estructura

Además de las anotaciones que están basadas en secuencia, se generaron las predicciones tridimensionales de estructura para evaluar si los microdominios seleccionados presentaban características diferenciales. Como se mencionó en la metodología, las estructuras fueron obtenidas mediante la API de NVIDIA (NVIDIA & DeepMind, 2024) y se visualizaron con el programa RCSB 3D View (Burley et al., 2024).

Para ilustrar las diferencias generales de los dominios detectados, se seleccionaron dos proteínas, una correspondiente al conjunto de datos de proteínas largas (P07883) y una al set de proteínas cortas (Q9AD92). Ambas estructuras fueron superpuestas para evaluar las similitudes en el plegamiento general (Figura 3), esto nos permite observar que a pesar de que los dominios cortos tienen un tamaño reducido, se pueden hacer conformaciones tridimensionales (Figura 4).



Figura 3. Superposición estructural entre una proteína con dominio largo y una con dominio corto. La figura muestra una superposición estructural entre una proteína P07883, correspondiente con un dominio largo (>100 aa) y una proteína con dominio corto (<100 aa, en color verde) correspondiente a Q9AD92. Las estructuras fueron visualizadas mediante RCSB 3D View (Burley et al., 2024). La estructura verde es el microdominio identificado en ambas herramientas de anotación (FoldSeek; (van Kempen et al., 2023 y ScanProsite; Edwards et al., 2007), mientras que la estructura en fucsia corresponde al dominio largo alineado para evidenciar diferencias en tamaño y

conformación. Los colores y los elementos visuales evidencian solamente el tipo de dominio y su longitud relativa.




Figura 4. Estructura tridimensional de predicha para la proteína O34163 de *Brachyspira hyodysenteriae*. Esta proteína presenta una esquema predicho por AlphaFold2 (Jumper et al., 2021), con un dominio de 77 aminoácidos (color dorado). La visualización fue obtenida mediante la herramienta RCSB 3D View (Burley et al., 2024). El modelo muestra una conformación compacta, con hélices alfa definidas que sugieren estabilidad estructural a pesar del tamaño pequeño del dominio.

Por otro lado, para los modelos estructurales predichos, se hizo una relación con las anotaciones de los términos derivados de InterPro, Gene Ontology y FoldSeek. En cada entrada se registró el término principal, la clasificación por el nombre GO; MF, “*Molecular function*” o BP, “*Biological Process*”, por sus siglas en inglés, al conjunto de datos al que pertenecían respecto a su longitud y el grupo biológico del que son parte. En la tabla 3 se resumen las anotaciones estructurales y funcionales, usadas posteriormente en los análisis comparativos.

Tabla 3. Grupos funcionales de proteínas secretadas, términos GO asociados y clasificación biológica con respecto al término

Domain_ID	GO_ID	GO_Name	Ontology	Length_group	Bio_group
Q9AD92_36_76	GO:0005198	Structural molecule activity	MF	short	Chaplin
Q9KYG7_47_87	GO:0007155	Cell adhesion	BP	short	Chaplin
Q9L1J9_34_74	GO:0007155	Cell adhesion	BP	short	Chaplin
Q9X9Z2_41_81	NA	NA	NA	short	PE/PPE

P9WIG7_1_90	GO:0007155	Cell adhesion	BP	long	PE/PPE
Q79FR5_4_94	NA	NA	NA	long	Lipase
Q9KYH3_38_78	GO:0007155	Cell adhesion	BP	short	Chaplin
O34163_1_77	GO:0048037	Cofactor binding	MF	short	ACP
O34163_1_77	GO:0000036	Acyl carrier activity	MF	short	ACP
O34163_1_77	GO:0008610	Lipid biosynthesis	BP	short	ACP
P81719_11_63	GO:0004252	Serine-type endopeptidase activity	MF	short	Protease
P81719_11_63	GO:0006508	Proteolysis	BP	short	Protease
Q79FR3_1_93	GO:0007155	Cell adhesion	BP	long	Big-1
Q79FR3_1_93	GO:0007156	Homophilic cell adhesion	BP	long	Big-1
P9WIG6_1_90	GO:0006955	Immune response	BP	long	PE/PPE
Q9AD93_39_79	GO:0007155	Cell adhesion	BP	short	Chaplin
Q9AD93_119_159	NA	NA	NA	short	Chaplin
P07883_33_309	GO:0004553	Hydrolase activity	MF	long	GH16
P07883_33_309	GO:0005975	Carbohydrate metabolism	BP	long	GH16
P07883_33_309	GO:0005509	Calcium ion binding	MF	long	GH16
O07783_7_130	GO:0016787	Hydrolase activity	MF	long	PIN/VapC
O07783_7_130	GO:0000287	Magnesium ion binding	MF	long	PIN/VapC
O07783_7_130	GO:0004540	RNA nuclease activity	MF	long	PIN/VapC
O07783_7_130	GO:0090729	Toxin activity	MF	long	PIN/VapC
O53168_340_472	GO:0008234	Cysteine-type peptidase	MF	long	NlpC/P60
O53168_340_472	GO:0052047	Symbiont-mediated cytolysis	BP	long	NlpC/P60
O53289_8_86	GO:0008234	Cysteine-type peptidase	MF	short	NlpC/P60

O53289_8_86	GO:0052047	Symbiont-mediated cytolysis	BP	short	NlpC/P60
O53289_102_174	GO:0004647	Phosphoserine phosphatase	MF	short	HAD/PSP
O53289_102_174	GO:0006564	L-serine biosynthesis	BP	short	HAD/PSP
L0T2H7_4_94	GO:0008234	Cysteine-type peptidase activity	MF	long	NlpC/P60
L0T2H7_4_94	GO:0071555	Cell wall organization	BP	long	NlpC/P60
L0T2H7_4_94	GO:0006508	Proteolysis	BP	long	NlpC/P60
Q79FU0_1_92	NA	NA	NA	long	PE/PPE
Q79FB3_1_93	NA	NA	NA	long	PE/PPE
I6Y8K5_1_93	NA	NA	NA	long	PE/PGRS
P15636_474_553	GO:0004252	Serine endopeptidase	MF	long	PKD
P15636_474_553	GO:0006508	Proteolysis	BP	long	PKD
P15636_474_553	GO:0005576	Extracellular region	CC	long	PKD
P15636_474_553	GO:0016787	Hydrolase activity	MF	long	PKD
P15636_474_553	GO:0008236	Serine peptidase activity	MF	long	PKD
P15636_555_653	GO:0004252	Serine endopeptidase	MF	long	PKD
P15636_555_653	GO:0006508	Proteolysis	BP	long	PKD
P81717_23_158	GO:0008745	Amidase activity	MF	long	Amidase_2
P81717_23_158	GO:0071555	Cell wall organization	BP	long	Amidase_2
P81717_23_158	GO:0042742	Defense response to bacterium	BP	long	Amidase_2
P81717_23_158	GO:0009253	Peptidoglycan catabolism	BP	long	Amidase_2
P81717_23_158	GO:0000270	Peptidoglycan turnover	BP	long	Amidase_2

Grupos funcionales identificados y sus términos GO asociados

Se identificó que seis proteínas, es decir, un (27,27%) de las proteínas carecen de un término GO anotado. El restante (72,73%) se concentran principalmente en las familias con dominios representados en PKD (16,7%) o PE/PPE (14,6%) y algunos dominios Chaplin, mostrando una diferencia notable entre anotaciones funcionales, basadas en estructura de las proteínas cortas, con respecto a las proteínas largas. Finalmente, la distribución por ontología, se clasifica en BP “*Biological Process*” (39,6%) MF “*Molecular Function*” (58,3%) y CC, “*Cellular Component*” (2,1%).

Comparación de enriquecimiento funcional en proteínas cortas vs largas

Para evaluar diferencias globales en función de la longitud proteica, se comparó la distribución de anotaciones GO entre los subconjuntos de proteínas secretadas cortas (microdominios de ≤ 100 aminoácidos) y largas (> 100 aminoácidos) (Figura 5). Si bien el análisis de sobre-representación funcional mediante prueba hipergeométrica no arrojó términos significativos tras la corrección por FDR ($p < 0,05$ ajustado), sí emergieron tendencias claras de enriquecimiento diferencial entre ambos grupos. En términos generales, las proteínas cortas mostraron mayor prevalencia de funciones asociadas a interacciones superficie-superficie (*p. ej.*, adhesión), mientras que las proteínas largas estuvieron dominadas por actividades enzimáticas hidrolíticas relacionadas con la degradación de macromoléculas.




Figura 5. Volcano plot del análisis de sobre-representación funcional entre proteínas secretadas cortas y largas. Cada uno de los puntos representa un término de Gene Ontology (GO). El eje X representa el $\log_2$ de la razón de abundancia (long/short) para cada término GO, donde los valores negativos indican mayor contribución relativa del término GO en proteínas cortas y valores positivos mayor

contribución de proteínas largas. El eje Y muestra $-\log_{10}$ del p-valor obtenido mediante la prueba hipergeométrica previa a la realización de la corrección por FDR. La escala indica el nivel de significancia (números mayores, menor p-valor). Se pueden observar etiquetas incluidas para los términos más representativos.

Los términos asociados a adhesión celular (por ejemplo, GO:0007155) se encuentran desplazados hacia valores negativos ($\log_2FC < 0$), lo que indica que este tipo de funciones se presenta proporcionalmente con mayor frecuencia en proteínas cortas. En contraste, varios términos relacionados con actividades hidrolíticas (GO:0016787) y procesos de organización de la pared celular (GO:0071555) se desplazan hacia valores positivos ($\log_2FC > 0$), lo que sugiere una mayor representación en proteínas largas.




Figura 6. Gráfico comparativo de anotaciones GO entre proteínas secretadas cortas y largas. El gráfico de barras apiladas muestra la frecuencia de cada término de Gene Ontology (GO) en las proteínas cortas (azul) y largas (naranja). Cada barra corresponde a un término GO y su longitud refleja el número total de proteínas anotadas con ese término. La figura permite observar cuáles funciones celulares predominan en cada grupo de longitud. Las etiquetas laterales identifican los términos GO incluidos; la escala horizontal representa la cantidad de ocurrencias por grupo.

El análisis de la figura 6 de conteo, confirma las tendencias observadas: el grupo short domina en términos como adhesión celular (GO:0007155) presente en 4 proteínas cortas frente a 0 larga, así como en funciones relacionadas con unión de cofactores (GO:0048037) y actividad transportadora de acilos (GO:0000036). Por su parte, el grupo long presenta frecuencias claramente mayores en procesos degradativos y enzimáticos: por ejemplo, proteólisis (GO:0006508) y actividad peptidasa (incluyendo GO:0008234, peptidasa de cisteína, y GO:0004252, peptidasa de serina) muestran 3–4 ocurrencias en proteínas largas frente a ninguna en las cortas. Igualmente, términos vinculados a la organización de la pared celular (GO:0071555) y actividades generales

de hidrolasa (GO:0016787) se registran sólo en las proteínas largas. Aunque muchos términos GO tienen conteos muy bajos (1–2 incidencias) en uno u otro grupo, por la limitación de tamaño, la representación de ciertos términos es evidente.




Figura 7. Bubble plot del análisis de enriquecimiento funcional para términos de Gene Ontology. En la figura se observa a cada burbuja representando un término GO y se posiciona según su $\log_2(\text{Fold Change})$ (razón long/short) en el eje horizontal. Por otro lado, el color corresponde al valor de $-\log_{10}(\text{p-value})$ escala a la derecha, en el eje vertical. El tamaño de cada burbuja indica la frecuencia total del término GO en el conjunto analizado, mientras que la escala de color representa el nivel de significancia estadística (p-valor). Se incluyen etiquetas para los términos más representativos. Esta figura permite visualizar patrones globales de enriquecimiento entre proteínas secretadas cortas y largas.

El diagrama de la figura 7 nos muestra un patrón similar al del volcano plot: hacia el extremo derecho (proteínas largas) se observa la agrupación de términos como “*cell wall organization*” y “*hydrolase activity*”, cuyas burbujas presentan valores $\log_2\text{FC}$ positivos, lo que indica una mayor contribución relativa de estos procesos en proteínas largas. En contraste, hacia el extremo izquierdo (proteínas cortas) sobresale el término “*cell adhesion*”, representado por una burbuja amarilla y de mayor tamaño, con $\log_2\text{FC}$ negativo. Este desplazamiento indica una mayor presencia proporcional de funciones de adhesión en las proteínas cortas. Su tamaño refleja, además, que este término se registra en múltiples proteínas dentro del conjunto.

Es importante resaltar que ninguno de los términos GO examinados alcanzó significancia estadística tras la corrección de múltiples pruebas (ajuste Benjamini-Hochberg).

Discusión

El presente trabajo explora de manera integral la composición y la función de las proteínas secretadas bacterianas con evidencia experimental mediante un enfoque que integra información de secuencia, estructura tridimensional y microdominios conservados. La recuperación inicial de las proteínas secretadas evidenciadas experimentalmente, mostró un conjunto pequeño pero diverso, en el cual varias entradas carecían de anotaciones funcionales confiables según la secuencia primaria. La aplicación coordinada de búsquedas de motivos (InterProScan y ScanProsite), predicción estructural (AlphaFold2) y alineamientos rápidos de estructura (FoldSeek) permitió de esta forma, complementar y, en algunos dominios, se obtuvieron mejores resultados, especialmente en proteínas con regiones repetitivas como PE/PPE, donde la homología de secuencia es poco informativa. La comparación entre ambos métodos evidenció que a pesar de que hay dominios difíciles de detectar por motivos o perfiles, se presentan patrones estructurales que permiten asignar funciones. Además, la recuperación de términos GO y su análisis estadístico ofrecieron una perspectiva cuantitativa sobre la distribución funcional de estos dominios.

Análisis de proteínas cortas (≤ 100 aa) y largas (> 100)

La comparación entre los dos conjuntos de longitud nos sugiere que las proteínas secretadas cortas tienden a concentrar funciones muy específicas, mientras que las largas usualmente son más complejas. En el grupo de las proteínas cortas, predominan los chaplins de *Streptomyces coelicolor* y varias proteínas PE de *Mycobacterium tuberculosis*, además de un ACP y una proteasa corta. Los dominios chaplin mostraron identidad moderada con otras proteínas de esta familia y coincidencias robustas con el perfil PS51884 (Sigrist et al., 2013), con GO asociadas a “*structural molecule activity*” (GO:0005198) y “*cell adhesion*” (GO:0007155). Esto es consistente con su papel como componentes estructurales de la matriz hidrofóbica que recubre las hifas aéreas (Elliot et al., 2003) y sugiere que microdominios relativamente pequeños pueden ajustar la rigidez e hidrofobicidad de la proteína en función del contexto.

Por el contrario, el conjunto de proteínas largas (> 100 aa) incluye un repertorio más variado de dominios, entre ellos GH16, HAD/PSP, NlpC/P60, PIN/VapC, PKD y Amidase_2. Estas proteínas combinan funciones degradativas, de remodelación de la pared y de interacción con el hospedador. Por ejemplo, los dominios GH16 en P07883 se asocian a actividad hidrolasa de carbohidratos y presentan un sitio de unión a Ca^{2+} , con una coordinación que es clave para la estabilidad enzimática (Liberato et al., 2021), mientras que los dominios NlpC/P60 y Amidase_2 se relacionan con catabolismo del peptidoglicano y organización de la pared celular (Griffin et al., 2022). En conjunto, estos resultados apoyan la idea de que la longitud de la proteína se relaciona con el grado de modularidad funcional: las proteínas cortas concentran microdominios de adhesión o ensamblaje, mientras que las largas integran múltiples módulos catalíticos y de unión que permiten respuestas extracelulares más complejas.

Relación de anotaciones funcionales derivadas de estructura

La integración de predicciones estructurales con las anotaciones basadas en secuencia permitió mejorar una asignación funcional de varios dominios, especialmente los afectados por regiones repetitivas. Los modelos obtenidos con AlphaFold2 (Jumper et al., 2021) y comparados mediante FoldSeek (van Kempen et al., 2023), junto con las búsquedas de motivos en InterProScan (Jones et al., 2014) y ScanProsite, nos mostraron que dominios con baja identidad de secuencia mantienen algunos plegamientos y sitios activos muy similares a los descritos en la literatura. Esto fue evidente en chaplins, NlpC/P60, PIN/VapC y LipX, donde la homología estructural respaldó la asignación de actividades de adhesión, peptidasa o ribonucleasa, incluso cuando las proteínas carecían de los términos GO o estaban incompletos.

Las superposiciones estructurales entre los dominios largos y cortos nos revelan que los microdominios de longitud reducida pueden adoptar plegamientos compactos y bien definidos. Por ejemplo, el modelo de ACP de O34163, una proteína corta, se alineó con un TM-score de 0,94 y modelos de referencia, el que mostró la organización helicoidal típica de proteínas portadoras de acilos (Wu, 2009). De forma similar, la estructura de LipX (Q79FR5), identificada como una lipasa/esterasa de la familia PE (Priya et al., 2024), evidenció un plegamiento relacionado con hidrolasas de lípidos, a pesar de la ausencia de términos GO. Estos casos reflejan cómo la anotación guiada por estructura puede evidenciar la presencia de cofactores biosintéticos (ACP), lipasas de virulencia (LipX) o toxinas PIN/VapC (Griffin et al., 2022) en proteínas que, a partir de la secuencia primaria, aparecerían como “hipotéticas” o desconocidas.

Sin embargo, una fracción de dominios permaneció sin términos GO incluso después de incorporar la información estructural. Varios de estos corresponden a familias de proteínas PE/PPE y PE/PGRS o a fragmentos parciales de chaplin, familias ampliamente reconocidas por su variación antigénica y sus regiones repetitivas (Zhang et al., 2025; Bateman et al., 2021). Esto nos sugiere que las bases de datos estructurales y de ontologías aún fallan en capturar completamente la diversidad funcional de estos microdominios, lo que nos resalta la necesidad de combinar predicciones computacionales con validación experimental.

Grupos funcionales identificados y sus términos GO asociados

Los resultados de los grupos funcionales (Tabla 3) nos muestran que la mayoría de los dominios anotados se distribuye en ontologías de “*Molecular Function*” y “*Biological Process*”, predominando en actividades de hidrolasas, peptidasas, funciones de adhesión y procesos relacionados con metabolismo de carbohidratos y remodelación de la pared celular. Estos patrones son coherentes con la visión clásica del secretoma bacteriano como un repertorio de enzimas degradativas y factores de interacción huésped–microorganismo (Vollmer et al., 2008).

Dentro de estos grupos, varios dominios muestran bien la funcionalidad de las proteínas secretadas. Los chaplins se concentran en funciones de adhesión y actividad estructural (Sigrist et al., 2013; Elliot et al., 2003), mientras que los dominios PE/PPE, a pesar de su alta proporción de términos GO “NA”, se han asociado en la literatura a modulación inmune (Zhang et al., 2025), variación antigénica y adquisición de nutrientes (Banu et al., 2002). El dominio Big-1 de Q79FR3, usual de adhesinas intimin/invasin, actúa como conector entre el ancla de membrana y un dominio lectina (Leo, 2014), y en este estudio se asocia al término GO de adhesión celular y homofílica, lo que nos sugiere la incorporación de adhesinas en la maquinaria del secretoma bacteriano. Los dominios PKD en P15636 funcionan como módulos de unión a sustratos que, al igual que en la colagenasa MCP-01, podrían facilitar el acceso del dominio catalítico a componentes extracelulares (Wang et al., 2010). Finalmente, la Amidase_2 y HAD/PSP nos muestran la presencia de enzimas que actúan tanto en el recambio del peptidoglicano como en rutas biosintéticas de aminoácidos (Vollmer et al., 2008; Fagerholm et al., 2004).

Algo relevante, es que aproximadamente una cuarta parte de los dominios permaneció sin términos GO asignados, ubicándose dentro de familias PE/PPE, PE/PGRS y en la propia LipX. En estos casos, la falta de anotación refleja la ausencia de una descripción formal en Gene Ontology, en lugar de la ausencia de función biológica (Bateman et al., 2021). La combinación de evidencia estructural y funcional publicada, nos indica que muchas de estas proteínas participan en procesos de virulencia, interacción con el hospedador o formación de estructuras comunitarias, pero aún no han sido integradas en las ontologías. De esta manera, la distribución observada de términos GO revela que los microdominios secretados actúan como unidades funcionales que se pueden recombinar en proteínas de diferentes longitudes, y también deja en evidencia, los vacíos actuales en la anotación funcional de familias clave, que representan una buena proporción del secretoma bacteriano evaluado.

Comparación de enriquecimiento funcional en proteínas cortas vs largas

El análisis mostrado en la figura 5, de Volcano plot, mostró un patrón general indica que, aunque no se detectaron diferencias significativas, las proteínas cortas tienden a concentrar funciones asociadas a adhesión, mientras que las proteínas largas muestran una mayor contribución relativa de funciones enzimáticas y de remodelación celular. Este tipo de partición funcional entre proteínas de distinto tamaño ha sido reportado previamente en estudios de caracterización del secretoma y la superficie bacteriana (Desvaux et al., 2009)

Por otro lado, en el gráfico de barras apiladas, se presentan ciertos términos muestran incidencias muy reducidas (1–2 apariciones) en ambos grupos, lo que sugiere que corresponden a funciones más específicas o menos conservadas en el secretoma analizado. En conjunto, la distribución observada refleja una diferenciación clara entre proteínas cortas, más vinculadas a interacción y adhesión, y proteínas largas, asociadas principalmente a funciones catalíticas y de degradación extracelular. Esta separación

funcional coincide con patrones evolutivos descritos en familias enzimáticas secretadas y proteínas de superficie bacteriana (Freeman & Wimley, 2012).

Finalmente, dado el tamaño muestral limitado en el gráfico Bubble Plot, debido a las diferencias descritas, los resultados se deben interpretar como tendencias sugestivas más que como enriquecimientos categóricos. No obstante, la coherencia de estas tendencias con la naturaleza conocida de las proteínas, donde proteínas cortas suelen actuar como factores de adhesión y señalización, mientras que las proteínas largas tienden a ser enzimas extracelulares, lo que aporta un respaldo biológico a los resultados (Tsirigos et al., 2015).

Conclusiones

En términos generales, el secretoma analizado tiene dos patrones funcionales contrastantes. Por una parte, las proteínas cortas (≤ 100 aa) están dominadas por microdominios estructurales como los chaplin, las repeticiones PE/PPE y los motivos Big-1, asociados mayoritariamente a funciones de adhesión a superficies, variación antigénica y adaptación huésped-microbio. Esto sugiere que los simbioses invierten en factores de adhesión y comunicación, posiblemente para establecer colonias estables en el intestino del huésped o en ambientes externos. De esta forma, la identificación de lipasas y dominios de transporte de acilos en proteínas cortas apunta a actividades especializadas vinculadas con la modificación del entorno local.

Por otra lado, en las proteínas largas (> 100 aa) encontramos dominios hidrolíticos y enzimáticos. Entre ellos destacan NlpC/P60, GH16, Amidasa_2 y fosfoserina fosfatasa, implicados en la degradación de polisacáridos complejos, el recambio del peptidoglucano o la biosíntesis de serina. Estos hallazgos nos indican que el secretoma largo contribuye de manera significativa a la adquisición de nutrientes y a la remodelación de las estructuras celulares, roles relacionados con estrategias de competencia y supervivencia en entornos ricos en materia orgánica. Mientras que las proteínas cortas median interacciones superficiales y posiblemente modulaciones inmunitarias, las proteínas largas realizan tareas catalíticas relacionadas con el metabolismo extracelular.

Una observación es la ausencia de anotación GO. Esta carencia no implica ausencia de función, sino un vacío en las ontologías actuales que impide categorizar adecuadamente estas regiones. Resaltando la necesidad de ampliar las bases de conocimiento y de emprender estudios experimentales que validen sus funciones.

En conclusión, la aproximación integrativa adoptada en esta tesis permite comprender la diversidad funcional del secretoma bacteriano y ofrecer un marco reproducible para la anotación de proteínas secretadas en otros sistemas simbióticos. Se propone para futuras investigaciones, hacer una combinación de ensayos experimentales, modelado estructural y aprendizaje automático en una escala mayor, para convertir estas hipótesis

en conocimiento, ampliando así nuestra comprensión de la biología del secretoma bacteriano y los microdominios funcionales.

Referencias

Agarwal, V., & McShan, A. C. (2024). The power and pitfalls of AlphaFold2 for structure prediction beyond rigid globular proteins. *Nature Chemical Biology*, 20(8), 950–959. <https://doi.org/10.1038/s41589-024-01638-w>

Almagro Armenteros, J. J., Tsirigos, K. D., Sønderby, C. K., Petersen, T. N., Winther, O., Brunak, S., ... & Nielsen, H. (2019). SignalP 5.0 improves signal peptide predictions using deep neural networks. *Nature Biotechnology*, 37(4), 420–423. <https://doi.org/10.1038/s41587-019-0036-z>

Ardila Parrado, D. (2025). Supplementary Dataset – Secretome Annotation and Domain Analysis (*C. elegans* Microbiome) (Versión 1.0) [conjunto de datos]. Zenodo. <https://doi.org/10.5281/zenodo.17773537>.

Ardila, D. (2025). secretome-annotation-pipeline-DAP. GitHub. Disponible en: <https://github.com/dani-ardila/secretome-annotation-pipeline-DAP>.

Baetsen-Young, A., Wai, C. M., VanBuren, R., & Day, B. (2019). *Fusarium virguliforme* transcriptional plasticity is revealed by host colonization of corn versus soybean. *The Plant Cell*, 32(2), 336–351. <https://doi.org/10.1105/tpc.19.00697>

Banu, S., Honore, N., Saint-Joanis, B., Philpott, D., Prevost, M. C., & Cole, S. T. (2002). Are the PE–PPE proteins of *Mycobacterium tuberculosis* variable surface antigens? *Molecular Microbiology*, 44(1), 9–19.

Bateman, A., Martin, M. J., Orchard, S., Magrane, M., Agivetova, R., Ahmad, S., ... & UniProt Consortium. (2021). UniProt: the universal protein knowledgebase in 2021. *Nucleic Acids Research*, 49(D1), D480–D489. <https://doi.org/10.1093/nar/gkaa1100>

Blum, M., Andreeva, A., Cavalcanti Florentino, L., Chuguransky, S. R., Grego, T., Hobbs, E., ... & Bateman, A. (2024). InterPro: the protein sequence classification resource in 2025. *Nucleic Acids Research*, 53(D1), D444–D456. <https://doi.org/10.1093/nar/gkae1082>

Burley, S. K., Bhikadiya, C., Bi, C., Bittrich, S., Chen, L., Crichlow, G. V., Christie, C. H., Dalenberg, K., Di Costanzo, L., Duarte, J. M., Dutta, S., Feng, Z., Ganesan, S., Goodsell, D. S., Ghosh, S., Green, R. K., Guranović, V., Guzenko, D., ... Zhuravleva, M. (2024). RCSB Protein Data Bank: Structural biology data resource. *Nucleic Acids Research*, 52(D1), D427–D436. <https://doi.org/10.1093/nar/gkad1037>

Csardi, G., & Nepusz, T. (2006). The igraph software package for complex network research. *InterJournal, Complex Systems*, 1695.

Cock, P. J. A., Antao, T., Chang, J. T., Chapman, B. A., Cox, C. J., Dalke, A., Friedberg, I., Hamelryck, T., Kauff, F., Wilczynski, B., & de Hoon, M. J. L. (2009). Biopython: Freely available Python tools for computational molecular biology and bioinformatics. *Bioinformatics*, 25(11), 1422–1423. <https://doi.org/10.1093/bioinformatics/btp16>

Davey, N. E., Cowan, J. L., Shields, D. C., Gibson, T. J., Coldwell, M. J., & Edwards, R. J. (2012). SLiMPrints: conservation-based discovery of functional motif fingerprints in intrinsically disordered protein regions. *Nucleic Acids Research*, 40(21), 10628–10641. <https://doi.org/10.1093/nar/gks854>

Davies, G., & Henrissat, B. (1995). Structures and mechanisms of glycosyl hydrolases. *Structure*, 3(9), 853–859. [https://doi.org/10.1016/S0969-2126\(01\)00220-9](https://doi.org/10.1016/S0969-2126(01)00220-9)

Desvaux, M., Hébraud, M., Talon, R., & Henderson, I. R. (2009). Secretion and subcellular localizations of bacterial proteins: A semantic awareness issue. *Trends in Microbiology*, 17(4), 139–145. <https://doi.org/10.1016/j.tim.2009.01.004>

Dirksen, P., Assié, A., Zimmermann, J., Zhang, F., Tietje, A.-M., Arnaud Marsh, S., Félix, M.-A., Shapira, M., Kaleta, C., Schulenburg, H., & Samuel, B. (2020). CeMbio – The *Caenorhabditis elegans* microbiome resource. *G3: Genes|Genomes|Genetics*, 10(9), 3025–3039. <https://doi.org/10.1534/g3.120.401309>

Duan, Y., Santos-Júnior, C. D., Schmidt, T. S., Fullam, A., de Almeida, B. L., Zhu, C., & Coelho, L. P. (2024). A catalog of small proteins from the global microbiome. *Nature Communications*, 15(1), 7563. <https://doi.org/10.1038/s41467-024-51894-6>

Edgar, R. C. (2024). Protein structure alignment by Rseek improves sensitivity to remote homologs. *Bioinformatics*, 40(11), btae687. <https://doi.org/10.1093/bioinformatics/btae687>

Edwards, R. J., Davey, N. E., & Shields, D. C. (2007). SLiMFinder: A probabilistic method for identifying over-represented, convergently evolved, short linear motifs in proteins. *PLOS ONE*, 2(10), e967. <https://doi.org/10.1371/journal.pone.0000967>

Elliot, M. A., Karoonuthaisiri, N., Huang, J., Bibb, M. J., Cohen, S. N., & Buttner, M. J. (2003). The chaplins: a family of hydrophobic cell-surface proteins involved in aerial hyphae formation in *Streptomyces coelicolor*. *Genes & Development*, 17(14), 1727–1740. <https://doi.org/10.1101/gad.259003>

Elliot, M. A., Karoonuthaisiri, N., Huang, J., Bibb, M. J., Cohen, S. N., Kao, C. M., & Buttner, M. J. (2003). The chaplins: A family of hydrophobic cell-surface proteins involved in aerial mycelium formation in *Streptomyces coelicolor*. *Genes & Development*, 17(14), 1727–1740. <https://doi.org/10.1101/gad.264403>

Fagerholm, S. C., Hilden, T. J., & Gahmberg, C. G. (2004). P marks the spot: Site-specific integrin phosphorylation regulates molecular interactions. *Trends in Biochemical Sciences*, 29(9), 504–512. <https://doi.org/10.1016/j.tibs.2004.07.005>

Falcon, S., & Gentleman, R. (2007). Using GOstats to test gene lists for GO term association. *Bioinformatics*, 23(2), 257–258. <https://doi.org/10.1093/bioinformatics/btl567>

Fishbein, S., van Wyk, N., Warren, R. M., & Sampson, S. L. (2015). Phylogeny to function: PE/PPE protein evolution and impact on *Mycobacterium tuberculosis* pathogenicity. *Molecular Microbiology*, 96(5), 901–916. <https://doi.org/10.1111/mmi.12982>

Freeman, M. M., & Wimley, W. C. (2012). *A highly soluble, useful model for studying protein secretion and localization*. *Journal of Bacteriology*, 194(17), 4496–4503.

Frimpong Boadu, F., Lee, A., & Cheng, J. (2024). Deep learning methods for protein function prediction. *Proteomics*, 25(1-2), e2300471. <https://doi.org/10.1002/pmic.202300471>

Fujita, S., & Terada, T. (2024). Enhanced prediction of protein functional identity through the integration of sequence and structural features. *Computational and Structural Biotechnology Journal*, 23, 4124–4130. <https://doi.org/10.1016/j.csbj.2024.11.028>

Gálvez, E. J. C., Espinoza, J. L., Sahin, M., Lee, D., Zhu, Q., & Bhatt, A. S. (2024). A global catalog of small open reading frames and microproteins from human-associated and environmental microbiomes. *Nature Biotechnology*. <https://doi.org/10.1038/s41587-024-02155-6>

Gene Ontology Consortium. (2021). The Gene Ontology resource: enriching a GOLD mine. *Nucleic Acids Research*, 49(D1), D325–D334. <https://doi.org/10.1093/nar/gkaa1113>

Griffin, M. E., Klupt, S., Espinosa, J., & Hang, H. C. (2022). Peptidoglycan NlpC/P60 peptidases in bacterial physiology and host interactions. *Cell Chemical Biology*, 29(11), 1663–1677. <https://doi.org/10.1016/j.chembiol.2022.11.001>

Hamburger, Z., Brown, M. S., Isberg, R. R., & Bjorkman, P. J. (1999). Crystal structure of invasins: A bacterial integrin-binding protein. *Science*, 286(5438), 291–295. <https://doi.org/10.1126/science.286.5438.291>

Jaeger, K. E., Dijkstra, B. W., & Reetz, M. T. (1999). Bacterial biocatalysts: Molecular biology, three-dimensional structures, and biotechnological applications of lipases. *Annual Review of Microbiology*, 53, 315–351. <https://doi.org/10.1146/annurev.micro.53.1.315>

Johnson, N. L., Kotz, S., & Kemp, A. W. (2005). *Univariate discrete distributions* (3rd ed.). Wiley.

Jones, P., Binns, D., Chang, H. Y., Fraser, M., Li, W., McAnulla, C. & Hunter, S. (2014). InterProScan 5: Genome-scale protein function classification. *Bioinformatics*, 30(9), 1236–1240. <https://doi.org/10.1093/bioinformatics/btu031>

Jumper, J., Evans, R., Pritzel, A., Green, T., Figurnov, M., Ronneberger, O., & Hassabis, D. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature*, 596(7873), 583–589. <https://doi.org/10.1038/s41586-021-03819-2>

Kassambara, A. (2020). ggpubr: 'ggplot2' based publication ready plots. CRAN. <https://cran.r-project.org/package=ggpubr>

Kelly, G., Prasannan, S., Daniell, S., Fleming, K., Frankel, G., Dougan, G., Connerton, I., & Matthews, S. (1999). Structure of the cell-adhesion fragment of intimin from enteropathogenic *Escherichia coli*. *Nature Structural Biology*, 6(4), 313–318. <https://doi.org/10.1038/7545>

Leo, J. C., Oberhettinger, P., Schütz, M., & Linke, D. (2014). The inverse autotransporter family: Intimin, invasins and related proteins. *International Journal of Medical Microbiology*, 305(2), 276–282. <https://doi.org/10.1016/j.ijmm.2014.12.011>

Liberato, M. V., Prates, E. T., Gonçalves, T. A., Bernardes, A., Vilela, N., ... & Squina, F. M. (2021). Insights into the dual cleavage activity of the GH16 laminarinase enzyme class on β -1,3 and β -1,4 glycosidic bonds. *Journal of Biological Chemistry*, 296, 100385. <https://doi.org/10.1016/j.jbc.2021.100385>

Lin, H., Xing, J., Wang, H., Wang, S., Fang, R., Li, X., Li, Z., & Song, N. (2024). Roles of lipolytic enzymes in *Mycobacterium tuberculosis* pathogenesis. *Frontiers in Microbiology*, 15, 1329715. <https://doi.org/10.3389/fmicb.2024.1329715>

Lombard, V., Golaconda Ramulu, H., Drula, E., Coutinho, P. M., & Henrissat, B. (2014). The carbohydrate-active enzymes database (CAZy) in 2013. *Nucleic Acids Research*, 42(D1), D490–D495. <https://doi.org/10.1093/nar/gkt1178>

Lötter, A., Bruna, T., Duong, T. A., Barry, K., Lipzen, A., ... & Myburg, A. A. (2025). A haplotype-resolved reference genome for *Eucalyptus grandis*. *G3 (Bethesda)*, 15(7), jkaf112. <https://doi.org/10.1093/g3journal/jkaf112>

Luo, Y., Frey, E. A., Pfuetzner, R. A., Creagh, A. L., Knoechel, D. G., Haynes, C. A., Finlay, B. B., & Strynadka, N. C. J. (2000). Crystal structure of enteropathogenic *Escherichia coli* intimin–receptor complex. *Nature*, 405(6790), 1073–1077. <https://doi.org/10.1038/35016618>

McFall-Ngai, M., Hadfield, M. G., Bosch, T. C. G., Carey, H. V., Domazet-Lošo, T., Douglas, A. E., ... & Wernegreen, J. J. (2013). Animals in a bacterial world, a new imperative for the life sciences. *PNAS*, 110(9), 3229–3236. <https://doi.org/10.1073/pnas.1218525110>

Mi, H., Muruganujan, A., Ebert, D., Huang, X., & Thomas, P. D. (2019). PANTHER version 14. *Nucleic Acids Research*, 47(D1), D419–D426. <https://doi.org/10.1093/nar/gky1038>

Miravet-Verde, S., Ferrar, T., Espadas-García, G., Mazzolini, R., Gharrab, A., Sabido, E., Serrano, L., & Lluch-Senar, M. (2019). Unraveling the hidden universe of small proteins in bacterial genomes. *Molecular Systems Biology*, 15(2), e8290. <https://doi.org/10.15252/msb.20188290>

Mistry, J., Chuguransky, S., Williams, L., Qureshi, M., Salazar, G. A., ... & Bateman, A. (2021). Pfam: The protein families database in 2021. *Nucleic Acids Research*, 49(D1), D412–D419. <https://doi.org/10.1093/nar/gkaa913>

N. Hulo, A. Bairoch, V. Bulliard, L. Cerutti, E. De Castro, P. S. Langendijk-Genevaux, M. Pagni, & C. J. A. Sigrist. (2009). PROSITE: The PROSITE database of protein families, domains and functional sites. *Nucleic Acids Research*, 34(Database issue), D227–D230. <https://prosite.expasy.org/>

NVIDIA & DeepMind. (2024). AlphaFold2 API: Protein Structure Prediction Service (v1.0). NVIDIA Developer Documentation. <https://health.api.nvidia.com/deepmind/alphafold2>

pandas development team. (2020). pandas-dev/pandas: Pandas. Zenodo. <https://doi.org/10.5281/zenodo.3509134>

Pedersen, T. L. (2024). ggraph: An implementation of grammar of graphics for graphs and networks. CRAN. <https://cran.r-project.org/package=ggraph>

Podell, S., Blanton, J. M., & Huntemann, M. (2018). Pangenomic comparison of globally distributed Poribacteria genomes. *Environmental Microbiology*, 20(11), 4066–4079. <https://doi.org/10.1111/1462-2920.14466>

Priya, A., Kaur, N., Singh, R., Nadda, N., Rawat, D. S., & Kumar, R. (2024). Roles of lipolytic enzymes in Mycobacterium tuberculosis pathogenesis. *Frontiers in Microbiology*, 15, 1329715. <https://doi.org/10.3389/fmicb.2024.1329715>

Python Software Foundation. (2024). *Python Standard Library Documentation* (Version 3.12). Python.org. <https://docs.python.org/3/library/>

R Core Team. (2023). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. <https://www.R-project.org/>

- Rawlings, N. D., Barrett, A. J., & Bateman, A. (2010). MEROPS: the peptidase database. *Nucleic Acids Research*, 38(suppl_1), D227–D233. <https://doi.org/10.1093/nar/gkp971>
- Reitz, K., & Contributors. (2024). *Requests: HTTP for Humans* (Version 2.x). <https://requests.readthedocs.io/en/latest/>
- Rock, C. O., & Cronan, J. E. (1996). Acyl carrier protein: structure, function and biology. In D. E. Vance & J. E. Vance (Eds.), *Biochemistry of Lipids, Lipoproteins and Membranes* (pp. 1–36). Elsevier.
- Rolig, A. S., Sweeney, E. G., Kaye, L. E., DeSantis, M. D., Perkins, A., Banse, A. V., & Guillemin, K. (2018). A bacterial immunomodulatory protein with lipocalin-like domains facilitates host–bacteria mutualism in larval zebrafish. *eLife*, 7, e37172. <https://doi.org/10.7554/eLife.37172>
- Rudner, D. Z., & Losick, R. M. (2023). Small proteins in Gram-positive bacteria: discovery, function and prospects. *FEMS Microbiology Reviews*, 47(6), fud052. <https://doi.org/10.1093/femsre/fud052>
- Sawyer, E. B., Claessen, D., Haas, H., Hurgobin, B., & Dijkstra, B. W. (2011). The biofilm matrix: not just slime. *Trends in Microbiology*, 19(12), 609–617. <https://doi.org/10.1016/j.tim.2011.09.002>
- Sigrist, C. J. A., de Castro, E., Cerutti, L., Cuče, B. A., Hulo, N., Bridge, A., Bougueleret, L., & Xenarios, I. (2013). PROSITE: A documented database using patterns and profiles as motif descriptors. *Briefings in Bioinformatics*, 14(3), 245–251. <https://doi.org/10.1093/bib/bbs106>
- Sigrist, C. J. A., de Castro, E., Cerutti, L., Cuče, B. A., Hulo, N., Bridge, A., Bougueleret, L., & Xenarios, I. (2012). New and continuing developments at PROSITE. *Nucleic Acids Research*, 41(Database issue), D344–D347. <https://doi.org/10.1093/nar/gks1067>
- Škunca, N., Altenhoff, A., & Dessimoz, C. (2012). Quality of computationally inferred gene ontology annotations. *PLoS Computational Biology*, 8(5), e1002533. <https://doi.org/10.1371/journal.pcbi.1002533>
- Slaby, B. M., Hackl, T., Horn, H., Bayer, K., & Hentschel, U. (2017). Metagenomic binning of a marine sponge microbiome reveals unity in defense but metabolic specialization. *The ISME Journal*, 11(11), 2465–2478. <https://doi.org/10.1038/ismej.2017.101>
- Storz, G., Wolf, Y. I., & Ramamurthi, K. S. (2014). Small proteins can no longer be ignored. *Annual Review of Biochemistry*, 83, 753–777. <https://doi.org/10.1146/annurev-biochem-070611-102400>

Szczerbiak, P., Szydlowski, L. M., Wydmański, W., Renfrew, P. D., Koehler Leman, J., & Kosciółek, T. (2025). Large protein databases reveal structural complementarity and functional locality. *Nature Communications*, 16, 7925. <https://doi.org/10.1038/s41467-025-63250-3>

The Gene Ontology Consortium. (2021). *The Gene Ontology resource: Enriching a GOLD mine*. *Nucleic Acids Research*, 49(D1), D325–D334. <https://doi.org/10.1093/nar/gkaa1113>

The UniProt Consortium. (2023). *UniProt: the Universal Protein Knowledgebase in 2023*. *Nucleic Acids Research*, 51(D1), D523–D531. <https://doi.org/10.1093/nar/gkac1052>

Tsirigos, K. D., Peters, C., Shu, N., Käll, L., & Elofsson, A. (2015). *The TOPCONS web server for consensus prediction of membrane protein topology and signal peptides*. *Nucleic Acids Research*

Van Roey, K., Davey, N. E., Weatheritt, R. J., Toedt, G., Uyar, B., Altenberg, B., Budd, A., Diella, F., Dinkel, H., & Gibson, T. J. (2012). Attributes of short linear motifs. *Molecular BioSystems*, 8(1), 268–281. <https://doi.org/10.1039/c1mb05231d>

van Kempen, M., Kim, S. S., Tumescheit, C., Mirdita, M., Lee, J., Gilchrist, C. L. M., Söding, J., & Steinegger, M. (2023). Fast and accurate protein structure search with FoldSeek. *Nature Biotechnology*, 42(2), 243–246. <https://doi.org/10.1038/s41587-023-01773-0>

Varadi, M., Bertoni, D., Magana, P., Paramval, U., Pidruchna, I., Radhakrishnan, M., ... (2024). AlphaFold Protein Structure Database in 2024: providing structure coverage for over 214 million protein sequences. *Nucleic Acids Research*, 52(D1), D368–D375. <https://doi.org/10.1093/nar/gkad1011>

Virk, B., Jia, J., Maynard, C. A., Raimundo, A., Lefebvre, J., Richards, S. A., ... & Weinkove, D. (2016). Folate acts in *E. coli* to accelerate *Caenorhabditis elegans* aging independently of bacterial biosynthesis. *Cell Reports*, 14(7), 1611–1620. <https://doi.org/10.1016/j.celrep.2016.01.051>

Virk, B., Correia, G., Dixon, D. P., Feyst, I., Jia, J., Oberleitner, N., ... & Weinkove, D. (2012). Excessive folate synthesis limits lifespan in the *C. elegans*/*E. coli* aging model. *BMC Biology*, 10(1), 67. DOI: [10.1186/1741-7007-10-67](https://doi.org/10.1186/1741-7007-10-67)

Virtanen, P., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272. <https://doi.org/10.1038/s41592-019-0686-2>

Vollmer, W., Blanot, D., & de Pedro, M. A. (2008). Peptidoglycan structure and architecture. *FEMS Microbiology Reviews*, 32(2), 149–167. <https://doi.org/10.1111/j.1574-6976.2007.00094.x>

Walsh, K., & Guillemin, K. (2022). The impacts of microbiota on animal development and physiology. En *Evolution, biodiversity and a reassessment of the hygiene hypothesis* (pp. 177–196). Springer. https://doi.org/10.1007/978-3-030-91051-8_6

Wang, Y.-K., Zhao, G.-Y., Li, Y., Chen, X.-L., Xie, B.-B., Su, H.-N. & Zhang, Y.-Z. (2010). Mechanistic insight into the function of the C-terminal PKD domain of the collagenolytic serine protease Deseasin MCP-01. *Journal of Biological Chemistry*, 285(19), 14285–14291. <https://doi.org/10.1074/jbc.M109.087023>

Wickham, H. (2016). *ggplot2: Elegant graphics for data analysis*. Springer

Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., ... Yutani, H. (2019). Welcome to the tidyverse. *Journal of Open Source Software*, 4(43), 1686. <https://doi.org/10.21105/joss.01686>

Wu, B.-N., Zhang, Y.-M., Rock, C. O., & Zheng, J. J. (2009). Structural modification of acyl carrier protein by butyryl group. *Protein Science*, 18(1), 240–246. <https://doi.org/10.1002/pro.11>

Yu, G., Wang, L. G., Han, Y., & He, Q. Y. (2012). clusterProfiler: an R package for comparing biological themes among gene clusters. *OMICS*, 16(5), 284–287. <https://doi.org/10.1089/omi.2011.0118>

Zhang, Y., Zhang, J., Hara, H., & Kato, I. (2005). Insights into the PIN domain Toxin–Antitoxin Systems in Prokaryotes. *Molecular Microbiology*, 56(5), 1199–1211. <https://doi.org/10.1111/j.1365-2958.2005.04505.x>

Zhang, Z., Dong, L., Li, X., Deng, T., & Wang, Q. (2025). The PE/PPE family proteins of *Mycobacterium tuberculosis*: Evolution, function, and prospects for tuberculosis control*. *Frontiers in Immunology*, 16, 1606311. <https://doi.org/10.3389/fimmu.2025.1606311>

Anexos

Ardila, D. (2025). secretome-annotation-pipeline-DAP. GitHub. Disponible en: <https://github.com/dani-ardila/secretome-annotation-pipeline-DAP>. Este repositorio alberga el código y los scripts utilizados para filtrar, curar y analizar las proteínas secretadas del dominio Bacteria.

Ardila Parrado, D. (2025). Supplementary Dataset – Secretome Annotation and Domain Analysis (*C. elegans* Microbiome) (Versión 1.0) [conjunto de datos]. Zenodo. <https://doi.org/10.5281/zenodo.17773537>. Es el conjunto de datos complementario que acompaña al estudio del secretoma. Incluye listas de proteínas curadas, tablas de anotación funcional, coincidencias de dominios Pfam y Prosite, análisis de enriquecimiento GO, predicciones estructurales y algunas salidas intermedias generadas durante el procesamiento computacional.

Tablas y figuras dominios secretados. Disponible en: <https://docs.google.com/document/d/1jXj6BOhtYn4lwMKV8JPO-U3sTEvAzfdZyF8wUl-Ky4/edit>. Este documento que recopila las tablas y figuras de los dominios secretados analizados en la tesis, incluyendo la distribución de longitudes, frecuencia de dominios y gráficas comparativas.

Abreviaturas

Tabla 9. Listado de abreviaturas utilizadas en el estudio

Abreviatura	Significado
aa	Aminoácidos.
AFDB	<i>AlphaFold Database</i> , repositorio de estructuras proteicas predichas mediante AlphaFold.
GO	<i>Gene Ontology</i> , ontología de términos que describe procesos biológicos, funciones moleculares y componentes celulares.
HMM	<i>Hidden Markov Model</i> , modelo probabilístico utilizado para detectar patrones en secuencias biológicas.
IDDT	<i>local Distance Difference Test</i> , métrica para evaluar la precisión local de modelos estructurales.
Mtb	<i>Mycobacterium tuberculosis</i> , especie bacteriana modelo para estudios de PE/PPE.
PGRS	<i>PE-PGRS</i> , subfamilia de proteínas PE con regiones ricas en glicina (PGRS).
PL_secreted	<i>Predicted secreted protein</i> , etiqueta utilizada para indicar proteínas predichas como secretadas.
Pfam	<i>Protein Families Database</i> , base de datos que agrupa proteínas por familias y dominios conservados.
PPE/PE	<i>Proline-Proline-Glutamate / Proline-Glutamate</i> , familias de proteínas presentes en micobacterias caracterizadas por motivos repetitivos.
RMSD	<i>Root Mean Square Deviation</i> , medida de la desviación promedio cuadrática entre átomos de dos estructuras.
SWISS-PROT	Conjunto curado de entradas de UniProt con anotación manual.
TM-score	<i>Template Modeling score</i> , estadístico que cuantifica la similitud estructural entre dos proteínas.
WGS	<i>Whole Genome Shotgun</i> , estrategia de secuenciación genómica basada en fragmentación aleatoria.